経験を読むロボットは，どう賢くなるのか

AD から In-Context RL へ

研究の流れを，課題の変化から読む

01

出発点

学習する振る舞いを移す

02

適用範囲

教材・行動・領域を広げる

03

判断の改善

報酬や先読みを生かす

対象 12 研究 / 本編 16 枚＋文献 4 枚

まず俯瞰｜「経験で適応できるか」から，三つの問いへ

発展は一本の順番ではなく，共通の出発点から分岐している．

共通の出発点：過去の試行を読ませ，次の行動を変える

AD・DPT：モデルの重みを更新せず，入力する経験で適応する

A ｜使える範囲

学習過程を記録できない．
行動や仕事も変わる．

Noise / Headless / Vintix / Vintix II

B ｜判断の質

記録に失敗や遠回りがある．
そのまま真似してよいか．

DIT / Q 比較 / S-ICQL

C ｜選び方

行動する前に，その結果を
予測して比べられないか．

DICP

並行する軸：AMAGO ＝ RL による訓練　／　Lin et al. ＝成立条件の理論

「何が新しいか」は，どの制約を変えた研究なのかを見ると分かる．

[1] – [12] | 問いによる整理：下の配置は継承関係や性能順位ではない

論文一覧 1/2 | 基礎と，最初の分岐

番号は資料全体で共通．正式題名・著者・arXiv リンクは末尾にも掲載．

研究	発表先	解決アイデアを一言で
[1] AD	ICLR 2023	学習の進み方を，次の行動予測へ移す
[2] DPT	NeurIPS 2023	経験から，その課題の最適行動を教える
[3] 理論解析（Lin et al.）	ICLR 2024	何を学べるか，成立条件を理論で調べる
[4] AMAGO	ICLR 2024	長い履歴を使う方策を RL で訓練する
[5] Noise Distillation	ICML 2024	ノイズを減らしながら，改善する教材を作る
[6] Headless-AD	ICML 2024	固定の行動番号への依存を外す

論文ごとの手順より，共通の課題と，変えた部分を追う．

対象：[1] AD, [2] DPT, [3] 理論解析（Lin et al.）, [4] AMAGO, [5] Noise Distillation, [6] Headless-AD

論文一覧 2/2 | 範囲の拡大と，判断の改善

番号は資料全体で共通．正式題名・著者・arXiv リンクは末尾にも掲載．

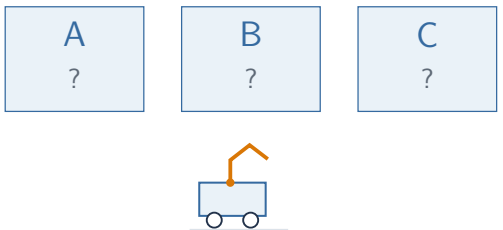
研究	発表先	解決アイデアを一言で
[7] Vintix	ICML 2025	教材の作り方を連続制御・多領域へ広げる
[8] DICP	ICLR 2025	未来を予測し，行動する前に候補を比べる
[9] Q 比較	arXiv 2025	行動模倣と，価値を学ぶ目的を比較する
[10] DIT	ICML 2025	見込みのよい行動に，模倣の重みを置く
[11] S-ICQL	ICLR 2026	経験の要約と価値学習を組み合わせる
[12] Vintix II	ICLR 2026	DPT を，多領域の連続行動へ拡張する

同じ「In-Context RL」でも，教材・価値・計画という別の軸がある．

対象：[7] Vintix, [8] DICP, [9] Q 比較, [10] DIT, [11] S-ICQL, [12] Vintix II

共通の具体例｜初めての倉庫で，充電できる部屋を探す

A・B・C のどこか一室だけで充電できる．正解は倉庫ごとに異なる．



訪問後は入口へ戻る．経験は残す．

試すたびに，次の行動が変わる

1 回目	A へ → 充電できない（0）
2 回目	B へ → 充電できない（0）
3 回目	C へ → 充電できた（1）
次から	C を選ぶ

事前学習：多くの倉庫で重みを学ぶ　→　利用時：重みを固定し，経験を追加

In-Context RL ＝入力した経験を手がかりに，その場の行動が適応する．

[1] AD / [2] DPT｜倉庫と行動列は説明用の例：原著の実験結果ではない

なぜ Algorithm Distillation？ ｜「上達する振る舞い」を移す

教師が最後に何をするかだけでなく，試行を通じてどう行動を変えたかを教材にする．

Expert Distillation（ED）

学習を終えた教師の行動を集める．
例：C へ，C へ，C へ…

主に「上手な振る舞い」を教材にする

Algorithm Distillation（AD）

教師が学習中に変えた行動を集める．
例：A で失敗 → B で失敗 → C で成功

探索・失敗・改善を含む履歴が教材になる

生徒は「この経験の後，教師は次に何をしたか」を繰り返し学ぶ．

この比較の本質は教材の違い．ED にも履歴や報酬を入力できる．

移したいのは学習する振る舞い．教師のコードや更新式そのものではない．

[1] AD §3・Expert Distillation 比較｜行動列は説明用

二つの出発点｜ AD と DPT は，何を正解として教えるかが違う

どちらも多くの課題の経験から訓練し，利用時は履歴で適応する．

AD ｜学習履歴を真似る

入力

教師が試した順の経験

↓

学習時の正解

その続きで教師が取った行動

DPT ｜経験から最適行動を教える

入力

集めた経験 ＋ 今の状態

↓

学習時の正解

その課題の最適行動

DPT の正解ラベルは訓練時に用意する．利用時に正解の部屋が分かるわけではない．

AD は「次に何をしたか」，DPT は「何をするのが最適か」を教える．

[1] AD §3 / [2] DPT §3｜原著の学習設定を比較

流れ A ｜教材を用意しやすくし，扱う仕事を広げる

教師が学習する全過程を，多数の課題で記録するのは大変．

[5] Noise Distillation

熟練方策の行動ノイズを徐々に減らす．
「不慣れ → 上手」の履歴を合成する．

[7] Vintix

この教材作りを連続行動に広げる．
多くの制御タスクで一つの方策を学ぶ．

ノイズ大
誤った部屋も選ぶ

→

ノイズ小
正解を選ぶ頻度が増す

→

ノイズなし
熟練方策の行動

「教師の訓練を記録する」から，「学びやすい履歴を作る」へ関心が広がる．

[5] Noise Distillation §3 / [7] Vintix §3.1 | ノイズの例は説明用

流れ A ｜行動の種類を変えるか，連続的な操作へ広げるか

どちらも適用範囲の拡張だが，取り除く制約が異なる．

[6] Headless-AD

倉庫ごとに，選べる部屋が違う．
行動を表すベクトルを使い，
その場の候補から行動を選ぶ．



[12] Vintix II

部屋の選択から，速度や操舵へ．
DPT の教え方に連続行動の生成器を
組み合わせ，多領域へ広げる．

経験 ＋ 現在の状態

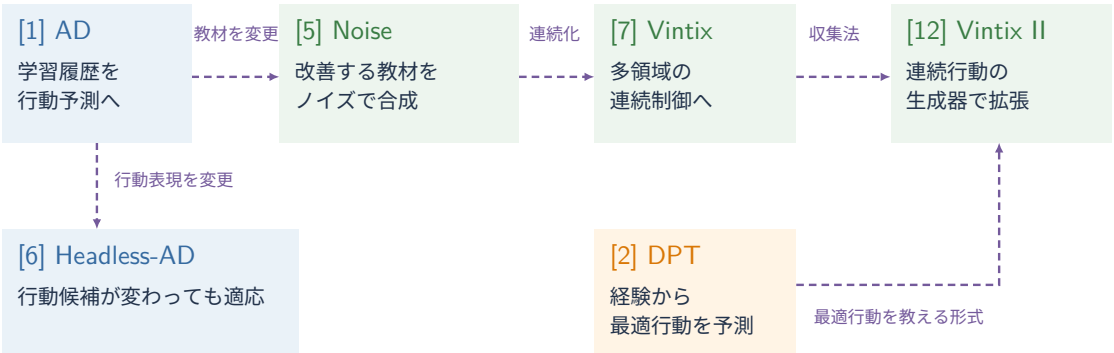
↓

速度・操舵などの連続値

「候補集合を柔軟にする」と「多様な連続操作を学ぶ」は，別の拡張である．

系統図 A ｜教材の工夫が連続制御へ広がり，DPT と合流する

紫の破線矢印＝原著が明示する方法の採用・変更．学習済み重みの継承は表さない．



AD 系列と DPT 系列は完全に分離していない．Vintix II で工夫が合流する．

[1] [2] [5] [6] [7] [12] | 根拠：Noise §3，Headless §3，Vintix §3.1，Vintix II §3

流れ B ｜不完全な経験を，そのまま真似してよいのか

倉庫の記録に遠回りが多いとき，よりよい経路を学べるだろうか．

[10] DIT	**よい行動を，より強く真似る** 将来の報酬にどれだけ有利かを推定し， 行動の模倣に重みを付ける．
[9] Q 比較	**行動予測と，RL の学習目的を比較する** 履歴から行動価値を学ぶことで， 模倣から何が改善するかを検証する．
[11] S-ICQL	**経験の要約と，価値による改善を組む** 履歴から課題の特徴を取り出し， その文脈で行動の価値と方策を学ぶ．

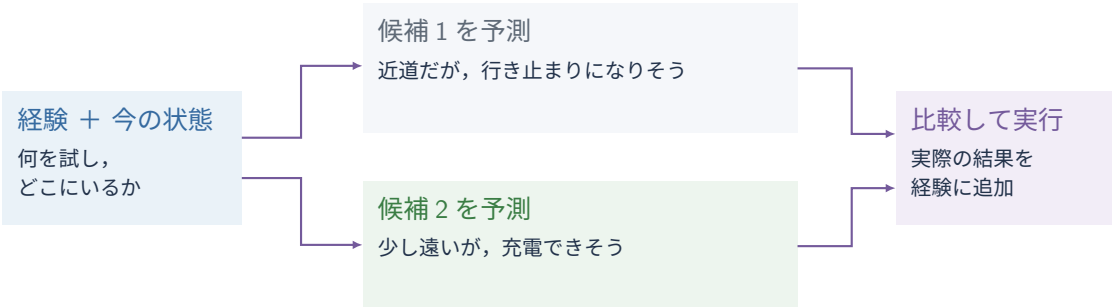
共通の狙いは経験の質を超えること．学習の仕方が異なる，並行した研究である．

[10] DIT §4 / [9] Q 比較 §3 / [11] S-ICQL §3 | 経路の例は説明用

流れ C ｜ DICP は，実際に動く前に未来を比べる

長い通路では，今よさそうな行動が，後で行き止まりにつながるかもしれない．

アイデア：行動の候補ごとに未来を予測し，よさそうな方を実行する．



価値を直接学ぶ方向と，未来を予測して選ぶ方向は，判断を改善する別の軸．

並行する研究｜RL で訓練する道と，仕組みを理論で問う道

AD の教材や行動予測を改良することだけが，研究の進み方ではない．

[4] AMAGO ｜訓練の別経路

長い試行履歴を使う方策を，
環境とのやり取りを通じて RL で訓練．
成功・失敗を長く覚え，
後の判断に生かすことを目指す．

[3] Lin et al. ｜理論の役割

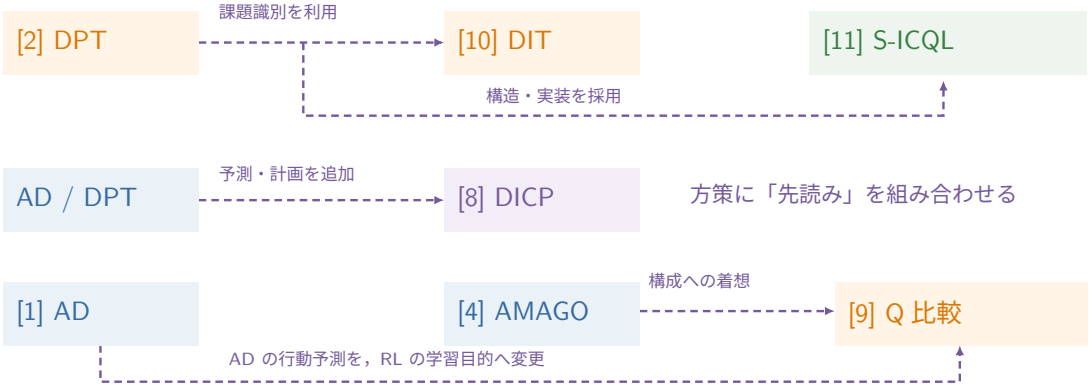
なぜ行動予測で適応が生じるのか．
何が表現でき，どんな条件が必要か．
実装できる判断とデータの条件を，
理論で明らかにする．

「どう訓練するか」と「なぜ成立するか」は，同じ適応能力を見る別の視点．

蒸留・RL 訓練・理論解析が並行し，互いを比較・理解する土台になっている．

系統図 B ｜価値・計画への分岐と，RL 訓練との接点

紫の破線矢印＝方法の採用・変更．横並びの研究が，順番に置き換わったわけではない．



判断をよくする方法は分岐している．構造や教材の採用が，系列をまたいで起こる．

[1] [2] [4] [8] – [11] | DIT §4.2，S-ICQL Appendix F，DICP §4，Q 比較 v5 §3

同じ倉庫の例で読む｜条件を変えると，必要な工夫が見える

どの方式が一番かより，いま困っている条件に対応する研究を探す．

例のどの条件を変える？	研究が加えるもの
たくさんの倉庫の教材がほしい	改善する履歴を合成する Noise → Vintix
部屋の候補や，ロボットの操作が違う	行動の表し方・生成の仕方を変える Headless-AD / Vintix II
記録には失敗や遠回りが混ざる	将来の報酬で，行動の良さを学ぶ DIT / Q 比較 / S-ICQL
充電まで何回も曲がり角がある	候補の未来を予測し，比較する DICP

研究の違いは，モデル名より「変えた条件」と「追加した学び方」に現れる．

[5] – [12] | 紹介者による応用例：各論文がこの倉庫で検証したという意味ではない

研究の動向｜適応の実現から，範囲と判断の質へ

三つの焦点が広がりながら，方法は分岐し，部分的に合流している．

1

適応は学べるか

経験を読んで
行動を変える能力を学ぶ

2

どこまで使えるか

教材・行動・領域の
制約を取り除く

3

よりよく判断できるか

報酬による改善と
未来の候補比較を加える

直列：AD → Noise → Vintix　　合流：DPT ＋ Vintix → Vintix II

並行：価値で改善する研究，先読みする研究，RL 訓練，理論解析

残る問い：未知の課題でも適応するか．必要な経験と計算を減らせるか．

「適応できる」から，「広く使え，経験からよりよく判断できる」へ．

[1] – [12] | 対象論文から読める傾向：厳密な年代区分ではない

文献一覧 1/4

正式題名・著者・発表先・参照した arXiv 版を掲載．リンクから原著へ．

[1] AD / ICLR 2023

In-context Reinforcement Learning with Algorithm Distillation

Michael Laskin et al.

arXiv:2210.14215v1

[2] DPT / NeurIPS 2023

Supervised Pretraining Can Learn In-Context Reinforcement Learning

Jonathan N. Lee et al.

arXiv:2306.14892v1

[3] 理論解析（Lin et al.）/ ICLR 2024

Transformers as Decision Makers: Provable In-Context Reinforcement Learning via Supervised Pretraining

Licong Lin, Yu Bai, Song Mei

arXiv:2310.08566v2

会議年を表示．AD の arXiv 初版は 2022 年．

書誌は添付資料の参照版を維持 | 全 12 本

文献一覧 2/4

正式題名・著者・発表先・参照した arXiv 版を掲載．リンクから原著へ．

[4] AMAGO / ICLR 2024

AMAGO: Scalable In-Context Reinforcement Learning for Adaptive Agents

Jake Grigsby, Linxi (Jim) Fan, Yuke Zhu

arXiv:2310.09971v4

[5] Noise Distillation / ICML 2024

Emergence of In-Context Reinforcement Learning from Noise Distillation

Ilya Zisman et al.

arXiv:2312.12275v3

[6] Headless-AD / ICML 2024

In-Context Reinforcement Learning for Variable Action Spaces

Viacheslav Sinii et al.

arXiv:2312.13327v6

文献一覧 3/4

正式題名・著者・発表先・参照した arXiv 版を掲載．リンクから原著へ．

[7] Vintix / ICML 2025

Vintix: Action Model via In-Context Reinforcement Learning

Andrey Polubarov et al.

arXiv:2501.19400v2

[8] DICP / ICLR 2025

Distilling Reinforcement Learning Algorithms for In-Context Model-Based Planning

Jaehyeon Son, Soochan Lee, Gunhee Kim

arXiv:2502.19009v1

[9] Q 比較 / arXiv 2025

Yes, Q-learning Helps Offline In-Context RL

Denis Tarasov et al.

arXiv:2502.17666v5

Q 比較：arXiv 初版は 2025 年，参照版 v5 は 2026 年．

文献一覧 4/4

正式題名・著者・発表先・参照した arXiv 版を掲載．リンクから原著へ．

[10] DIT / ICML 2025

In-Context Reinforcement Learning From Suboptimal Historical Data

Juncheng Dong et al.

arXiv:2601.20116v1

[11] S-ICQL / ICLR 2026

Scalable In-Context Q-Learning

Jinmei Liu et al.

arXiv:2506.01299v3

[12] Vintix II / ICLR 2026

Vintix II: Decision Pre-Trained Transformer is a Scalable In-Context Reinforcement Learner

Andrei Polubarov et al.

arXiv:2604.05112v1

DIT：ICML 2025，arXiv 初版は 2026 年．会議年と公開年を区別．

書誌は添付資料の参照版を維持 | 全 12 本