研究サーベイ

MoE × 強化学習

基礎から，研究の流れとつながりを読む

何を分担し，どの課題を解こうとしているのか

MoE の基礎

仕組みを具体例で理解する

研究の俯瞰

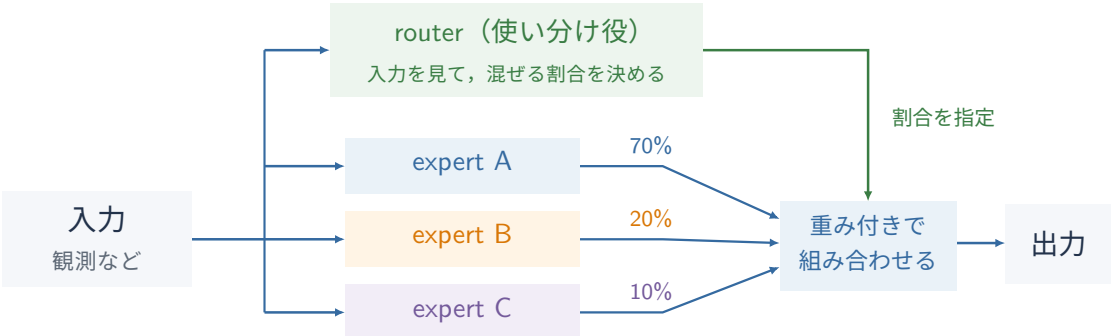
直列・並行・交わりを読む

13 論文の整理

短いアイデアと文献一覧

MoE とは？ ｜複数の計算役を，入力に応じて使い分ける

Mixture of Experts（専門家の混合）．expert は，計算を担うモデルの部品．



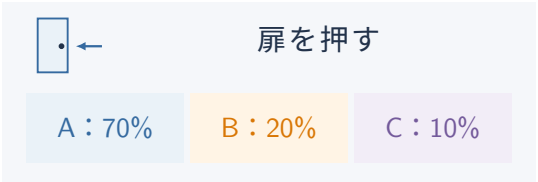
全ての出力を混ぜる例．一部の expert だけを選ぶ設計もある．

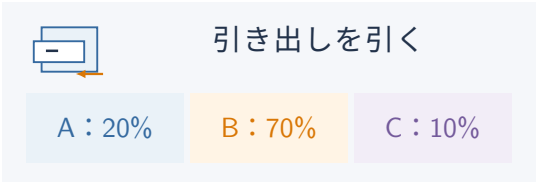
ポイントは「複数で計算する」ことと「入力に合わせて使い分ける」こと．

[B1] Shazeer et al. (2017), §2 | 入力に応じて出力を混ぜる基本形の模式図

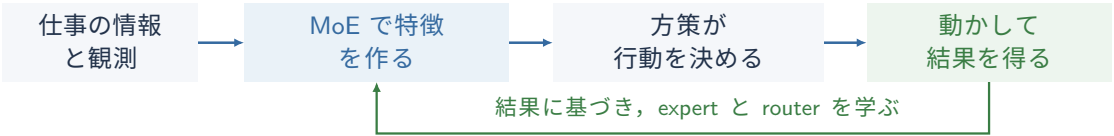
強化学習での例｜役割分担も，使い分けも学ぶ

MoE はモデルの構造の工夫．ここでは，ロボットの特徴処理に使う例を見る．





同じ A・B・C を使い，仕事の情報と観測に応じて混ぜ方を変える．



expert は，最初から熟練していなくてよい．分担の仕方も学習で育てる．

[2] Willi et al. (2024), §2 – 3 | 図と比率は説明用の例．実験結果ではない

論文一覧 1/2 | 中心となる二つの流れと接点

名前をクリックすると arXiv へ．番号は資料全体で共通．

A | 複数の仕事で共有する

[4] Soft Modularization
NeurIPS 2020 / 仕事に応じた共有と分担

[7] CARE
ICML 2021 / 仕事の文脈に応じた共有

[13] MOORE
ICLR 2024 / 共有する表現の多様性

B | 容量を生かし，学び続ける

[1] MoE Scaling
ICML 2024 / 大きなモデルを RL に生かす

[2] MoE in RL Settings
RLC 2024 / 複数・継続タスクへ検証を広げる

[12] SPHERE
ICML 2026 / 新たに学ぶ力を保つ

接点 | 多数の仕事 × 大きなモデル

[5] M3DT / ICML 2025
仕事の数とモデルの容量

[4] [7] [13] [1] [2] [12] [5] | 正式な文献一覧は末尾に掲載

論文一覧 2/2 | 環境への適応と，別の目的

同じ MoE でも，何を改善したいかが異なる．

環境や仕事の変化に対応する

[8] CPT / UAI 2021
環境に合う過去の経験を転移

[11] SAC-MoE / arXiv 2025
動きの性質が変わる環境に対応

[6] T2MIR / NeurIPS 2025
試行履歴を使った適応

分業を別の目的に生かす

[3] PMOE / arXiv 2021
複数の行動候補と探索

[9] SMOSE / AAAI 2025
制御の判断を説明しやすくする

[10] MENTOR / ICML 2025
視覚から少ない試行で学ぶ

ここでの位置は主な問いによる整理．研究は複数の流れにまたがる．

[8] [11] [6] [3] [9] [10] | 正式な文献一覧は末尾に掲載

研究の出発点｜共有したい，大きくしたい

対象 13 論文を，「解決したい課題の変化」から読む

同じ「分担と使い分け」でも，解決したい課題は一つではない．

二つの主な流れを追い，その接点と，並行する研究を見ていく．

出発点 A ｜経験を共有したい

複数の仕事を学ぶとき，
共通部分を使い回せないか．

多タスク学習・転移の関心

出発点 B ｜モデルを大きくしたい

増やしたモデルの容量を，
強化学習の改善に生かせないか．

深層 RL の容量・学習能力の関心

二つの流れが並行し，「多くの仕事を学ぶ」という課題で交わる．

研究の系統図｜並行して進み，問いが交わる

矢印は原著が示す先行課題への応答．点線は共通する問いによる関係．

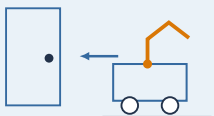


直列なのは個々の発展．俯瞰すると，複数の流れが並行・交差する．

[13] §1・3 / [2] §1・5 / [12] §1 / [5] §1 | 年は arXiv 初版年

流れ A ｜「一緒に学ぶ」から「役立つ共有」へ

例：倉庫ロボットに，扉を押す仕事と引き出しを引く仕事を教える．



扉を押す



引き出しを引く

共有したい部分

取手を見つけて，近づく．

仕事ごとに違う部分

力を加える向きが違う．

出発点

共通部分を学び直さずに済ませたい．

→

その先の問い

助け合い，邪魔しない共有とは？

共有を増やすだけでなく，共通性と違いの両方を生かす研究へ．

共有のアイデア｜何を使い回すかを工夫する

同じ「共有」でも，変える場所が異なる．

[4] Soft Modularization 部品のつながりを変える	仕事に応じて，共有する部品のつながりを 重み付きで組み替える． 狙い：共通部分を使い回しつつ，仕事ごとの違いを残す．
[7] CARE 説明文で特徴を混ぜる	仕事の説明文を手がかりに， 複数の特徴を混ぜる割合を決める． 狙い：意味の近い仕事の間で，共通する特徴を利用する．
[13] MOORE 特徴の重なりを減らす	expert が出す特徴を互いに直交させてから， 仕事ごとに組み合わせる． 狙い：共有する特徴が似たものばかりになるのを防ぐ．

接続を変える，文脈で混ぜる，重なりを減らす．共有の工夫に違いがある．

流れ B ｜容量を増やし，その容量で学び続ける

RL では，モデルを大きくするだけで学習が改善するとは限らない．

大きくする



増やした容量は
学習に役立つか？

条件を広げる



複数の仕事を同時に，
または順に学べるか？

学び続ける



学習が進んでも，
新しい経験で改善するか？

「過去の仕事を保つこと」と「新しい仕事を学べること」は，別の問題．

容量を増やす効果に加え，変わる経験から学び続けられる条件を問う．

[1] MoE Scaling / [2] MoE in RL Settings / [12] SPHERE

容量と持続のアイデア｜構造と学習を工夫する

容量の効果から，使い方の検証，学ぶ力の維持へ．

[1] MoE Scaling 容量を分担に使う	価値予測のネットワークに，複数の expert を滑らかに混ぜる層（Soft MoE）を組み込む． 狙い：増やしたモデルの容量を，学習の改善に生かす．
[2] MoE in RL Settings 有効な構成を確かめる	expert がネットワーク全体を担う構成も試し，配置と使い分け方を，複数・継続タスクで比べる． 狙い：どんな分業が有効かを，比較実験で明らかにする．
[12] SPHERE 特徴の偏りを抑える	expert 内・expert 間の特徴の偏りや重なりを抑える補助損失を加える． 狙い：新しい経験から改善する力を保つ．

構造を変える，条件を比べる，学ぶ力を保つ．研究する範囲が広がる．

二つの流れの接点｜仕事が増えると，両方が必要

例：倉庫の仕事が，押す・引くから，運ぶ・積む・仕分けるへ増える．

仕事を増やすと

学習が互いに邪魔しやすい．

モデルを大きくすると

増やした容量を生かしたい．

[5] M3DT ｜学習を分けて，干渉を減らす

共通部分を学び，仕事のグループごとに expert を育てる．
最後に，どの expert をどれだけ使うかを学ぶ．

合流するのは研究の目的．一つの手法を順番に改良した系列ではない．

別の問いも並行する｜変化への適応と，分業の目的

共有や容量の研究と並んで，「どんな場面で役立てるか」も広がっている．

環境が変わったら？



状況に合う経験を使う

CPT [8] / SAC-MoE [11] / T2MIR [6]

何を良くしたい？

探索	複数のやり方を試す [3]
説明	判断を人が追える [9]
試行効率	画像から少ない試行で学ぶ [10]

「共有」「容量」「適応」「別の評価目的」は，重なりながら並行する．

[8] [11] [6] / [3] [9] [10]｜横並びは目的の比較であり，後継関係ではない

適応のアイデア｜使う経験を，何から決めるか

どれも変化への対応を目指すが，使う手がかりと仕組みが異なる．

[8] CPT 動きが合う経験を使う	実際の状態変化に合う過去の環境モデルを重視し， そのモデルに対応する方策を再利用する． 狙い：転移先で得た経験から，役立つ転移元を判断する．
[11] SAC-MoE 今の状態から使い分ける	状態に応じて expert を選ぶ方策を学び， 苦手な環境条件を重点的に練習する． 狙い：動きの性質が途中で変わる環境に対応する．
[6] T2MIR 入力と仕事の両方で分担	状態・行動・報酬の履歴を読み，入力要素ごとの 分業と，仕事ごとの分業を組み合わせる． 狙い：試した結果を使って，新しい仕事に対応を変える．

環境の動き，今の状態，試行の履歴．使い分けの手がかりが異なる．

別の目的へのアイデア｜探索・説明・試行効率

分業の仕組みを，それぞれの目的に合わせて変える．

[3] PMOE 行動の選択肢を残す	行動を複数の確率分布の混合で表し， 良い行動を出す expert を使うように学ぶ． 狙い：複数のやり方を残しながら探索する．
[9] SMOSE 単純な制御則を選ぶ	複数の線形の制御則から，状態に応じて一つを選ぶ． 選択部も単純な形にして，判断を追いやすくする． 狙い：どの状態で，どの制御則を使ったかを読み取る．
[10] MENTOR 分業と，停滞からの回復	画像の特徴処理を分担し，成績が良かった 過去のモデルを参考に，重みに摂動を加える． 狙い：学習の停滞を和らげ，少ない試行で上達する．

選択肢を保つ，判断を読みやすくする，学習を立て直す，という工夫．

俯瞰して押さえるのは，三つの関係

研究の発展は，「先行課題への応答」「並行した関心」「問いの交わり」で読む．

直列｜残った課題への応答

例：[1] → [2] → [12]

容量の効果を確かめ，検証を広げ，学び続ける条件を問う．

並行｜違う問いを追う

共有・容量・環境への適応・探索や説明などが併存する．

交わり｜複数の問いを一緒に扱う

例：[5] M3DT

多くの仕事を学ぶには，共有の設計と容量の活用が関わる．

共通する問いは，「役立つ分担を，どんな場面で，どう保つか」．

文献一覧 1/4

正式題名・著者・発表先・参照版．arXiv リンクから原著を開ける．

[1] MoE Scaling
Mixtures of Experts Unlock Parameter Scaling for Deep RL

Obando-Ceron et al. | ICML 2024 https://arxiv.org/abs/2402.08609v3

[2] MoE in RL Settings
Mixture of Experts in a Mixture of RL settings

Willi et al. | RLC 2024 https://arxiv.org/abs/2406.18420v1

[3] PMOE
Probabilistic Mixture-of-Experts for Efficient Deep Reinforcement Learning

Ren et al. | arXiv 2021 https://arxiv.org/abs/2104.09122v1

[4] Soft Modularization
Multi-Task Reinforcement Learning with Soft Modularization

Yang et al. | NeurIPS 2020 https://arxiv.org/abs/2003.13661v2

本文の論文番号に対応 | 著者名は筆頭著者＋ et al. で表記

文献一覧 2/4

正式題名・著者・発表先・参照版．arXiv リンクから原著を開ける．

[5] M3DT
Mastering Massive Multi-Task Reinforcement Learning via Mixture-of-Expert Decision Transformer
Kong et al. | ICML 2025 https://arxiv.org/abs/2505.24378v1

[6] T2MIR
Mixture-of-Experts Meets In-Context Reinforcement Learning
Wu et al. | NeurIPS 2025 https://arxiv.org/abs/2506.05426v3

[7] CARE
Multi-Task Reinforcement Learning with Context-based Representations
Sodhani et al. | ICML 2021 https://arxiv.org/abs/2102.06177v2

[8] CPT
Contextual Policy Transfer in Reinforcement Learning Domains via Deep Mixtures-of-Experts
Gimelfarb et al. | UAI 2021 https://arxiv.org/abs/2003.00203v2

本文の論文番号に対応 | 著者名は筆頭著者＋ et al. で表記

文献一覧 3/4

正式題名・著者・発表先・参照版．arXiv リンクから原著を開ける．

[9] SMOSE

SMOSE: Sparse Mixture of Shallow Experts for Interpretable Reinforcement Learning in Continuous Control Tasks

Vincze et al. | AAAI 2025 https://arxiv.org/abs/2412.13053v1

[10] MENTOR

MENTOR: Mixture-of-Experts Network with Task-Oriented Perturbation for Visual Reinforcement Learning

Huang et al. | ICML 2025 https://arxiv.org/abs/2410.14972v3

[11] SAC-MoE

SAC-MoE: Reinforcement Learning with Mixture-of-Experts for Control of Hybrid Dynamical Systems with Uncertainty

D'Souza et al. | arXiv 2025 https://arxiv.org/abs/2511.12361v1

本文の論文番号に対応 | 著者名は筆頭著者＋ et al. で表記

文献一覧 4/4

正式題名・著者・発表先・参照版．arXiv リンクから原著を開ける．

[12] SPHERE

SPHERE: Mitigating the Loss of Spectral Plasticity in Mixture-of-Experts for Deep Reinforcement Learning

Luo et al. | ICML 2026 https://arxiv.org/abs/2605.04712v2

[13] MOORE

Multi-Task Reinforcement Learning with Mixture of Orthogonal Experts

Hendawy et al. | ICLR 2024 https://arxiv.org/abs/2311.11385v2

[B1] MoE の基礎

Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer

Shazeer et al. | arXiv 2017 https://arxiv.org/abs/1701.06538v1