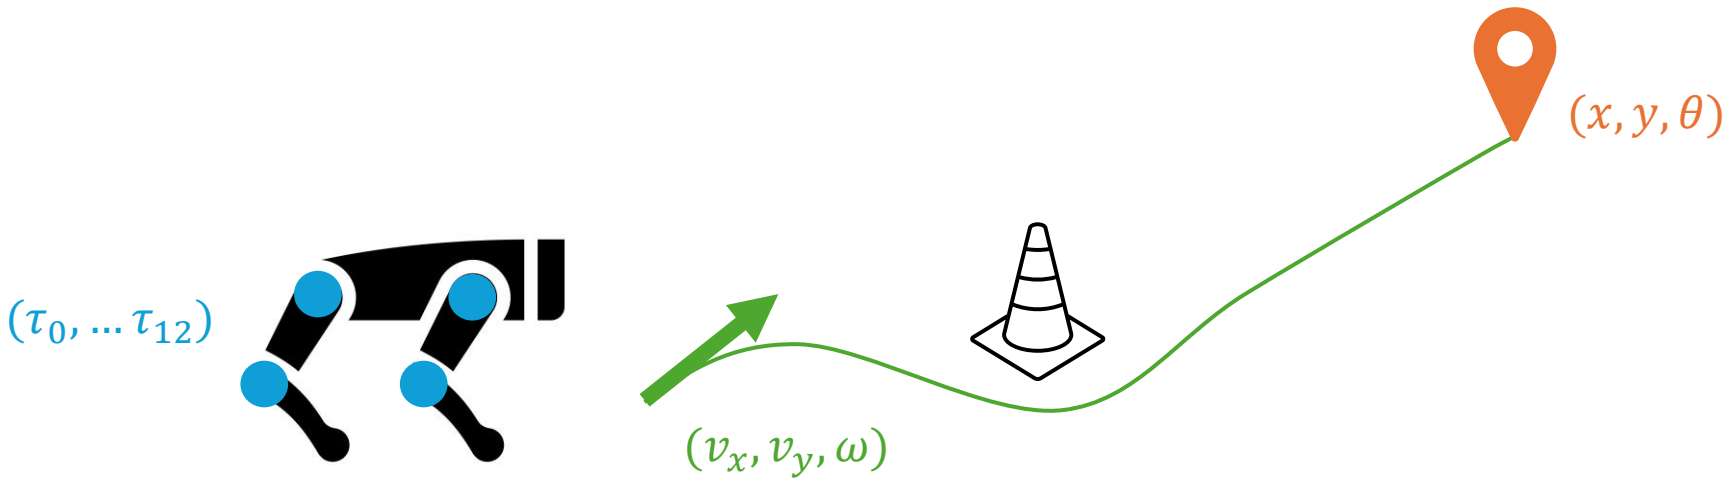
# サーベイ

サブタイトル

# 研究テーマ

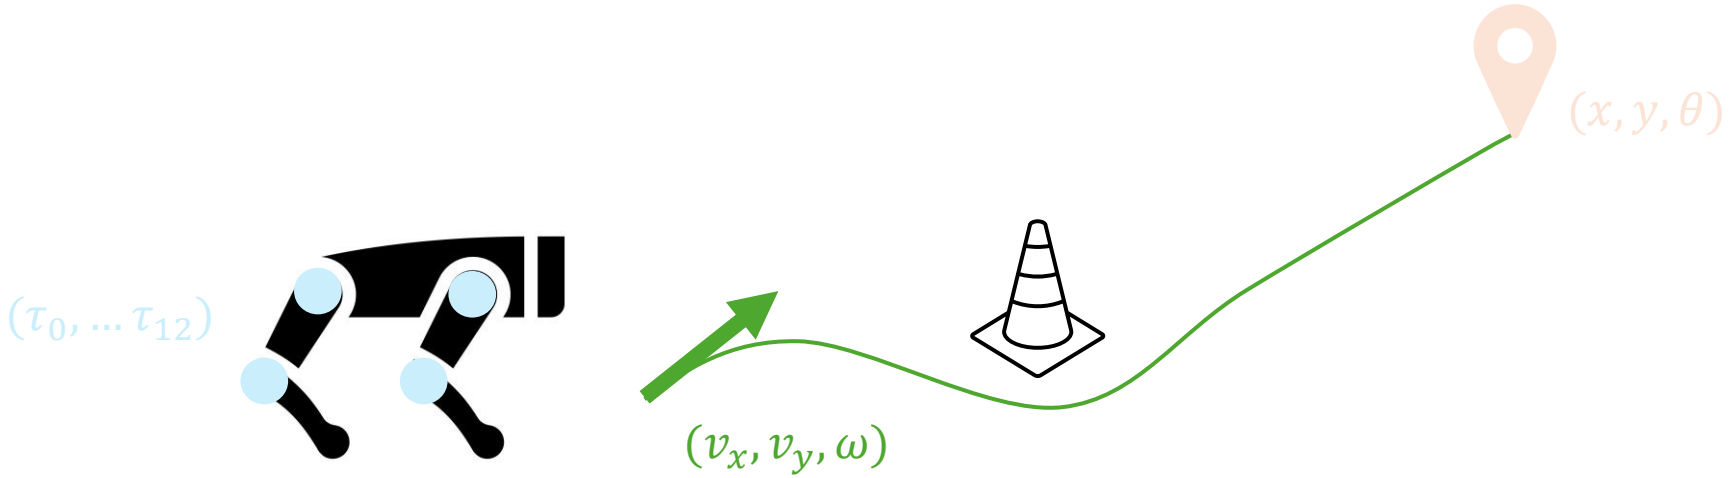
# 研究テーマ：安全保障と好み選択を両立できる局所プランナ



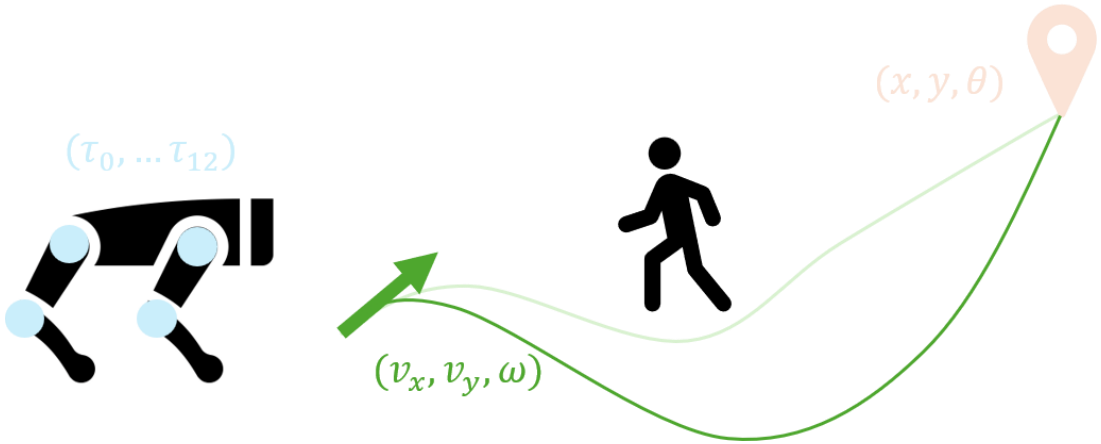
# 研究テーマ：安全保障と好み選択を両立できる局所プランナ



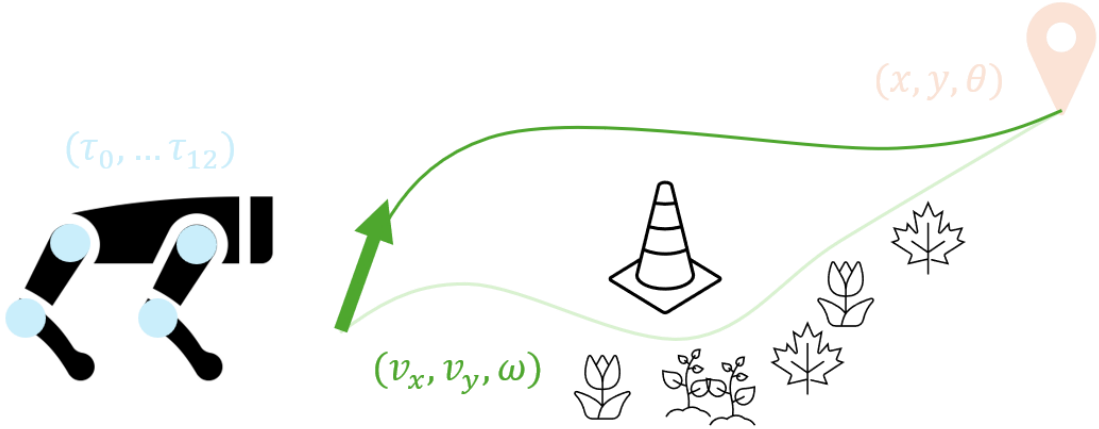



# 研究テーマ：安全保障と好み選択を両立できる局所プランナ




**安全保障**



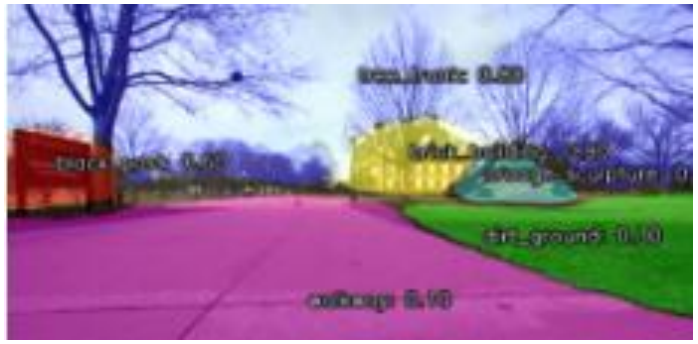

**好み選択**

# 好み と 安全 に関する論文

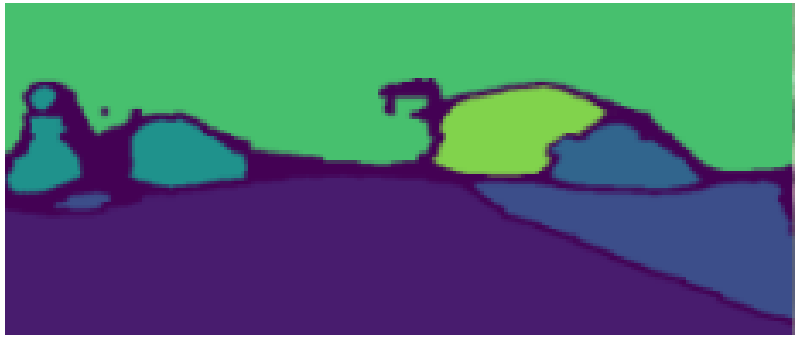
好み：CATNAV: Cached Vision-Language Traversability for Efficient Zero-Shot Robot Navigation

安全：SEA-Nav: Efficient Policy Learning for Safe and Agile Quadruped Navigation in Cluttered Environments

# CATNAV: Cached Vision-Language Traversability for Efficient Zero-Shot Robot Navigation



CLIP Seg



Cost map



Select Route

二段階で好みを選ぶ

# 背景

ロボットの物理的能力に応じた走破性リスクの評価が必要
屋外→動的障害物や地形への配慮
屋内→人や壊れやすいものへの配慮

従来手法
・学習ベース　→　大量の学習データが必要、OODに弱い
・VLM　→　コストにすると柔軟な人間らしい推論能力を生かせない、計算リソース
・VLA　→　解釈可能性が低い

# 従来手法

・学習ベース　→　大量の学習データが必要、OODに弱い
・VLM　→　コストにすると柔軟な人間らしい推論能力を生かせない、計算リソース
・VLA　→　解釈可能性が低い

まとめると・・・

課題
1. 少ないアノテーションデータでも、高い推論能力が欲しい
2. 少ないリソースでも高周波数で動いてほしい
3. 数値だけではなく、人間らしい社会的かつ柔軟な判断をしてほしい

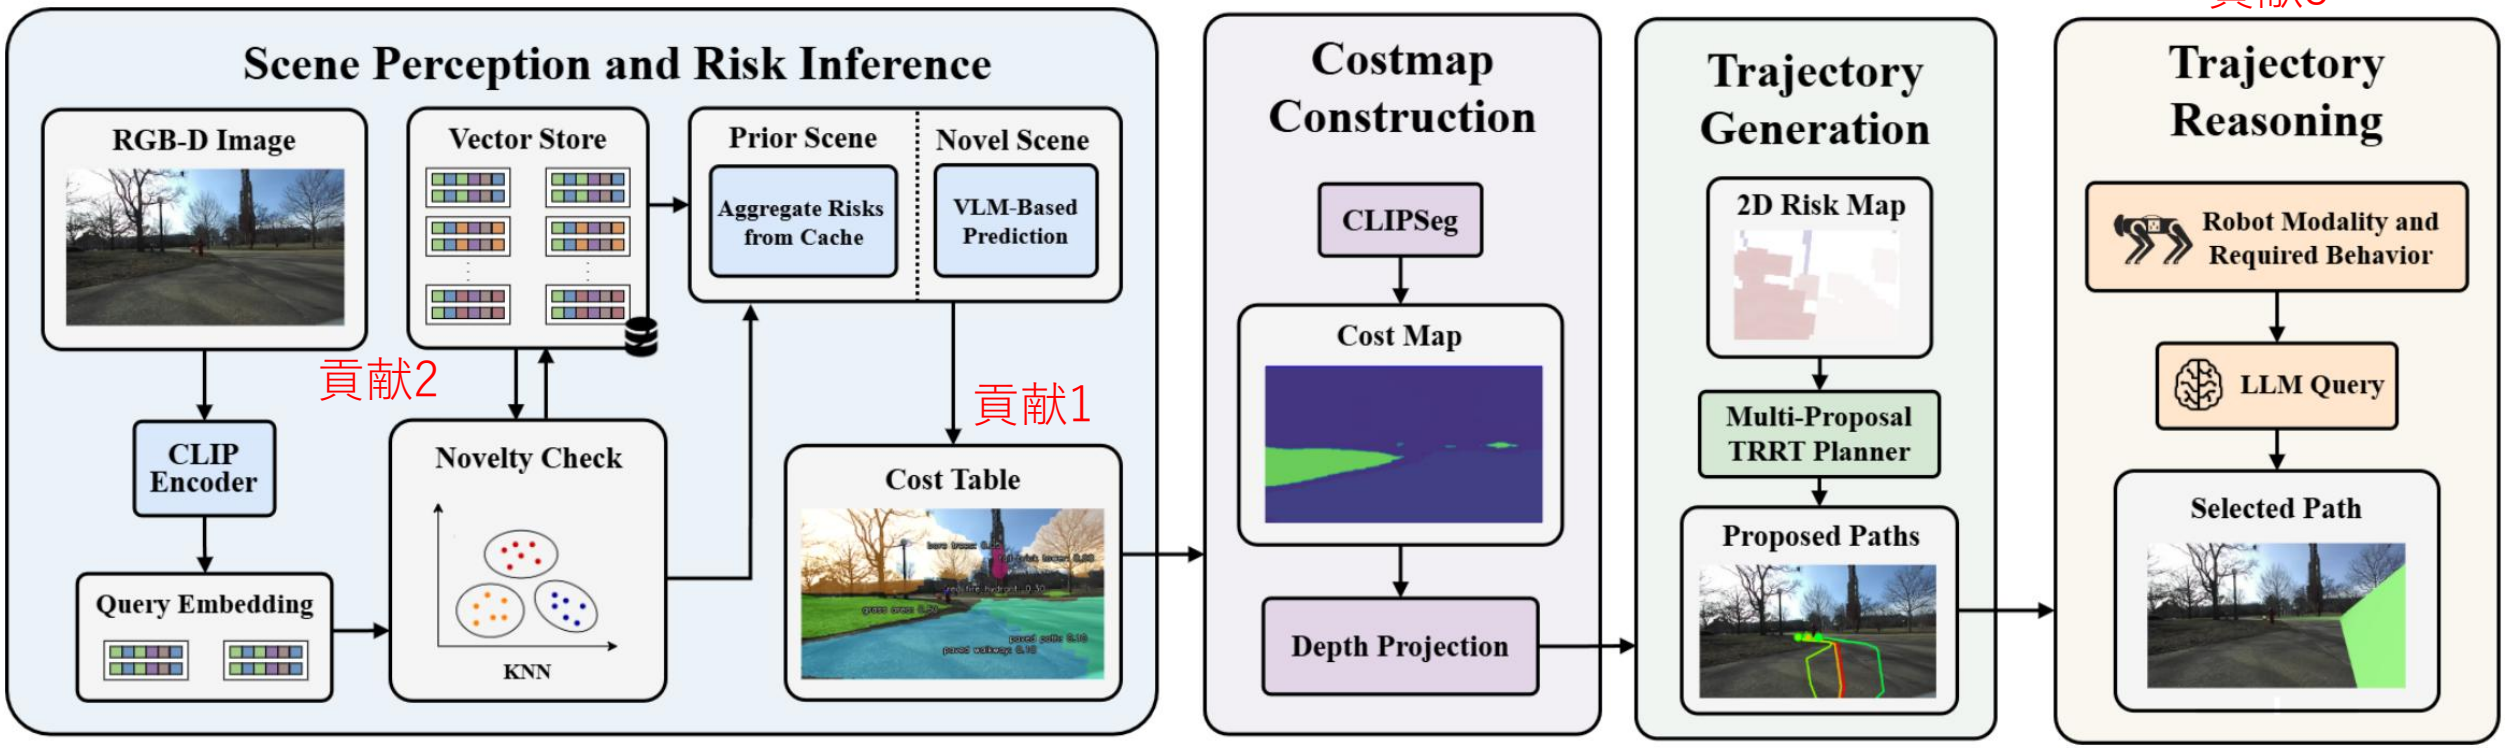
あとできれば、人間にとって解釈可能であったらうれしい…

# 貢献

1. タスク固有の学習は必要とせず、VLMの推論能力で意味的リスク値をゼロショットで推定
2. 画像の特徴量から類似シーンを検出し、リスク評価を再利用することでリソースの削減
3. RGB画像に乗せた複数経路から、視覚的に安全な経路を柔軟にVLMに選ばせる

VLMの柔軟な推論能力を生かしつつ、できれば必要なリソースを減らしたい

# 方法



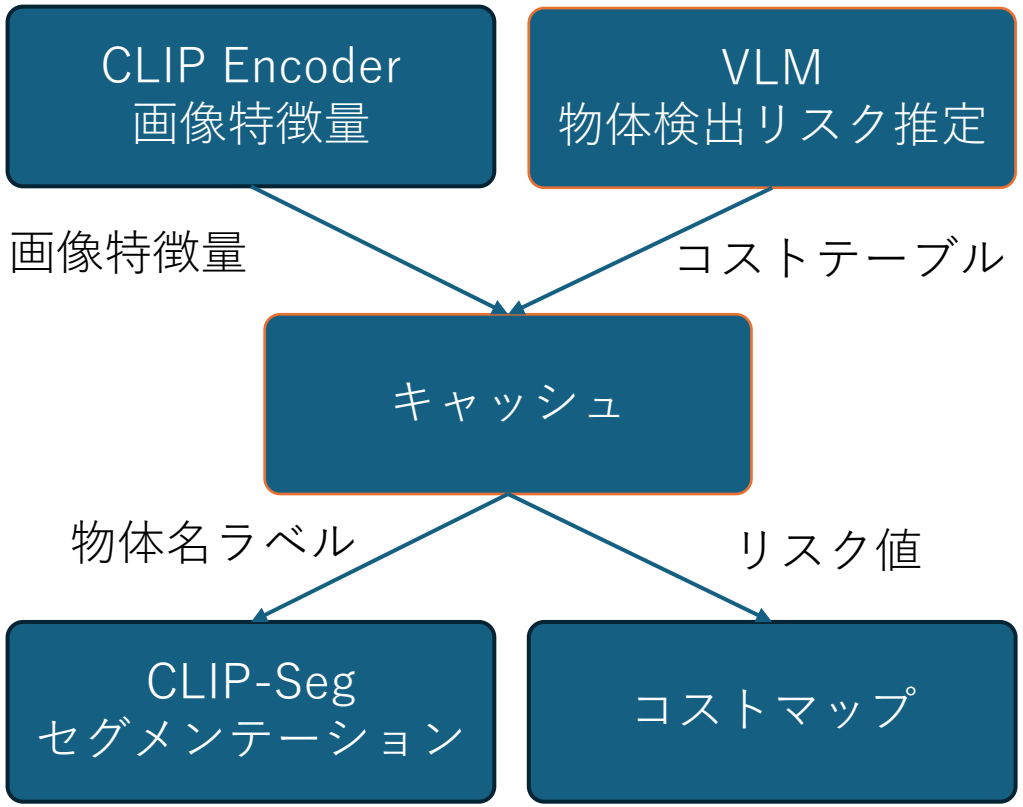

ゼロショット認識

リスク数値ベースの
経路生成

柔軟な
経路選択

認識、経路生成、経路選択の順で行動が決まる

# ゼロショット認識

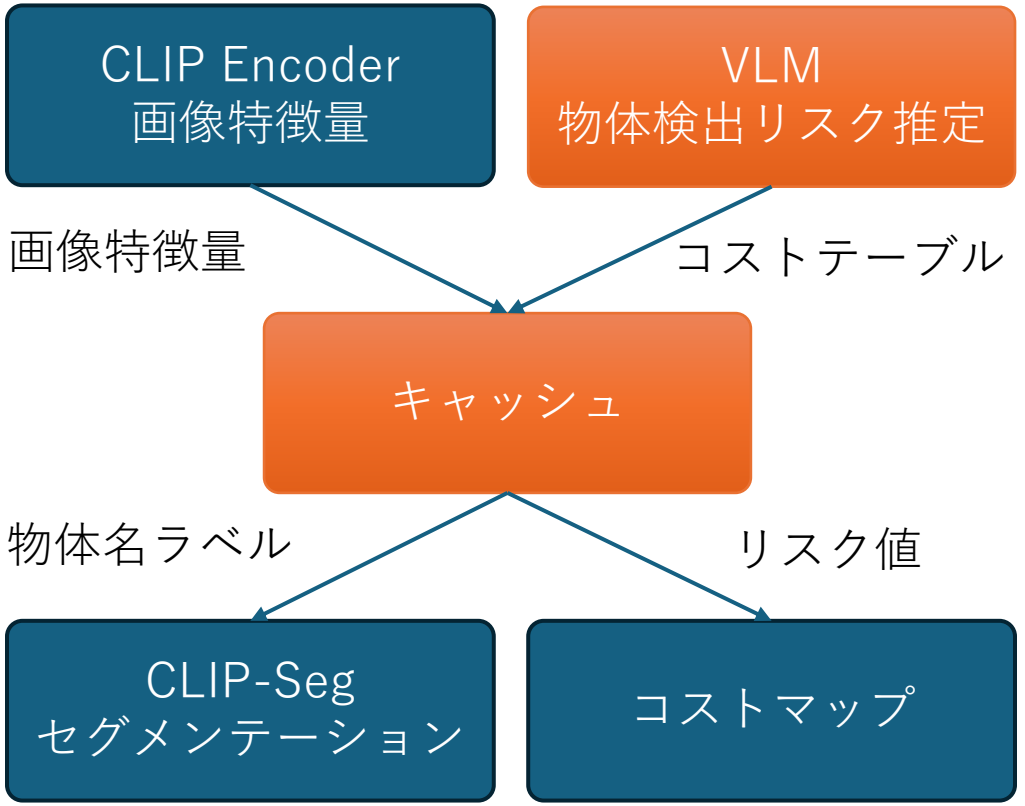

CLIP Encoder
画像特徴量
VLM
物体検出リスク推定
画像特徴量
コストテーブル
キャッシュ
物体名ラベル
リスク値
CLIP-Seg
セグメンテーション
コストマップ

# VLM：物体検出とリスク推定(貢献1)

画像中の物体名とそのリスクを評価
コストテーブルを作成させる

[物体名, リスク値]

処理はかなりは重く、遅延が発生する可能性がある



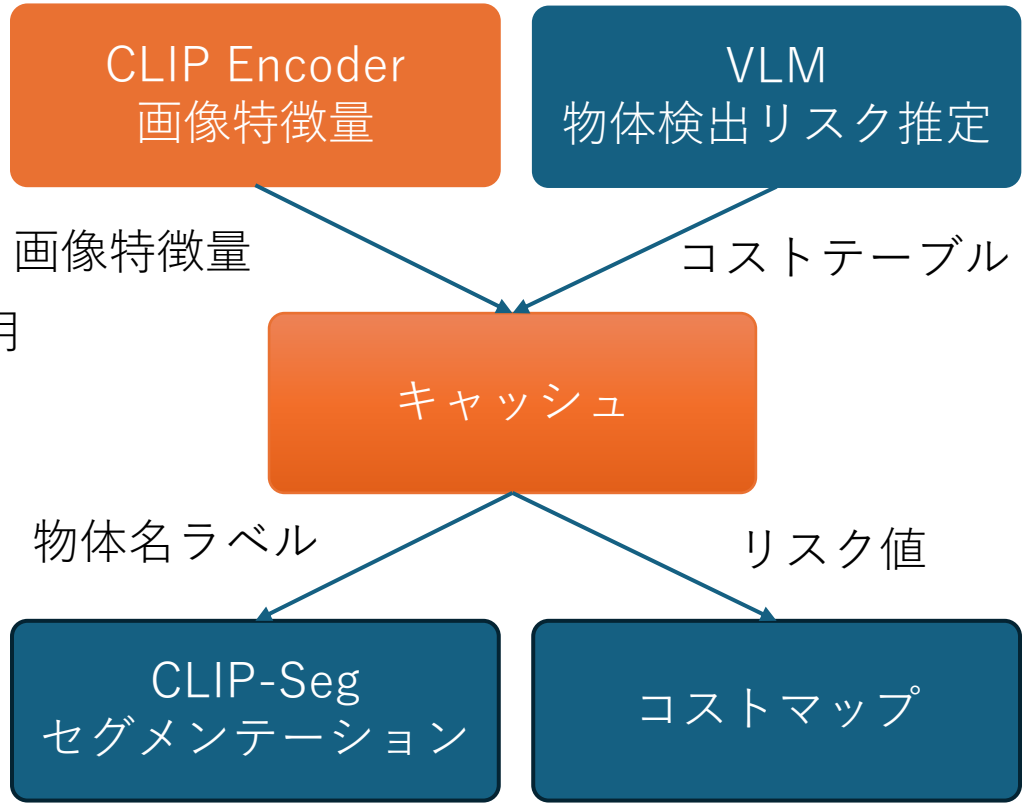

VLMの知識だけでリスクを見積もれるが、毎回処理したくない

# CLIP Encoder：画像特徴量抽出

CLIP Encoderで画像の特徴量ベクトルを抽出
768次元に圧縮

キャッシュ内の特徴量ベクトルと比較
→閾値よりも特徴量が違う場合のみ物体検出を実行
→それ以外はキャッシュ内の近傍k個のリスク値を使用

$$\bar{r}_c = \frac{1}{|C|} \sum_{i \in C} r_c^{(i)}, \quad C = \{ i \in \mathcal{N}_k \mid c \in \mathcal{T}_i \}. \qquad (2)$$



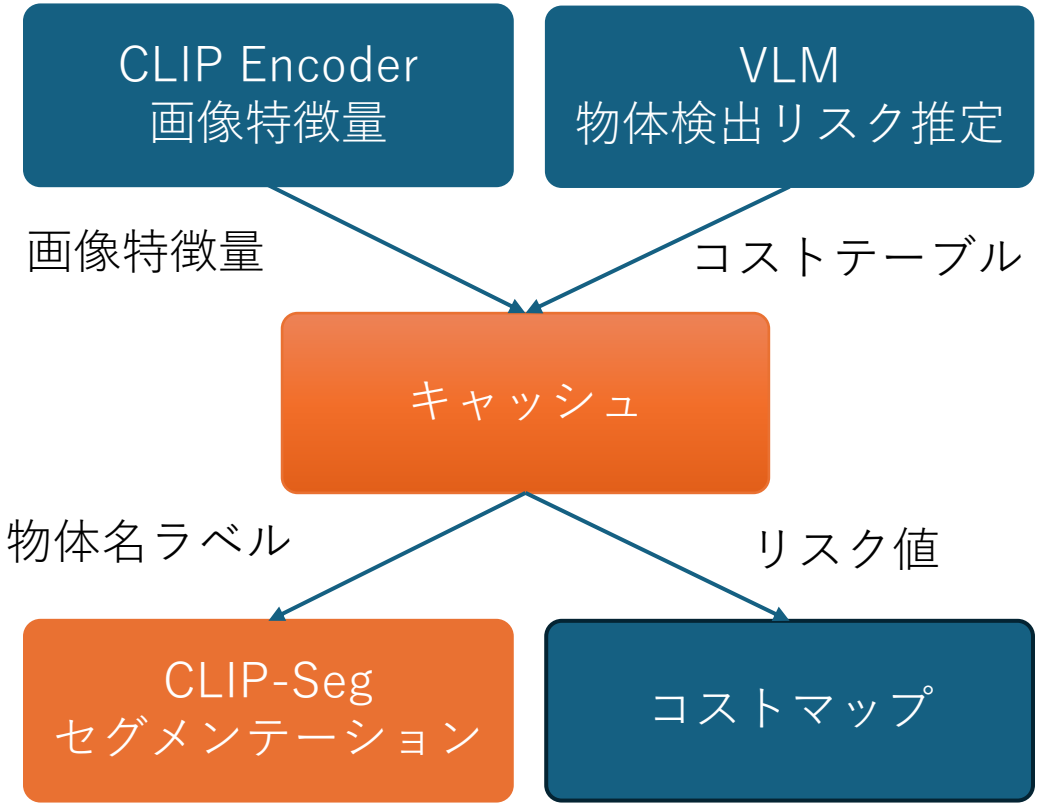

画像特徴量を比較することで、似ている場合はVLMへの問い合わせを控える

# CLIP-Seg：セグメンテーション

コストテーブル内の物体名ラベルとの反応値を得る
最も反応が高かった物体が映っていると推定

微小領域ごとの数値が得られるため
バイリニア補間で画像サイズまで引き延ばして使用

$$k_c = \arg\max_k p_k(u, v) \cdot r_k, \qquad (3)$$

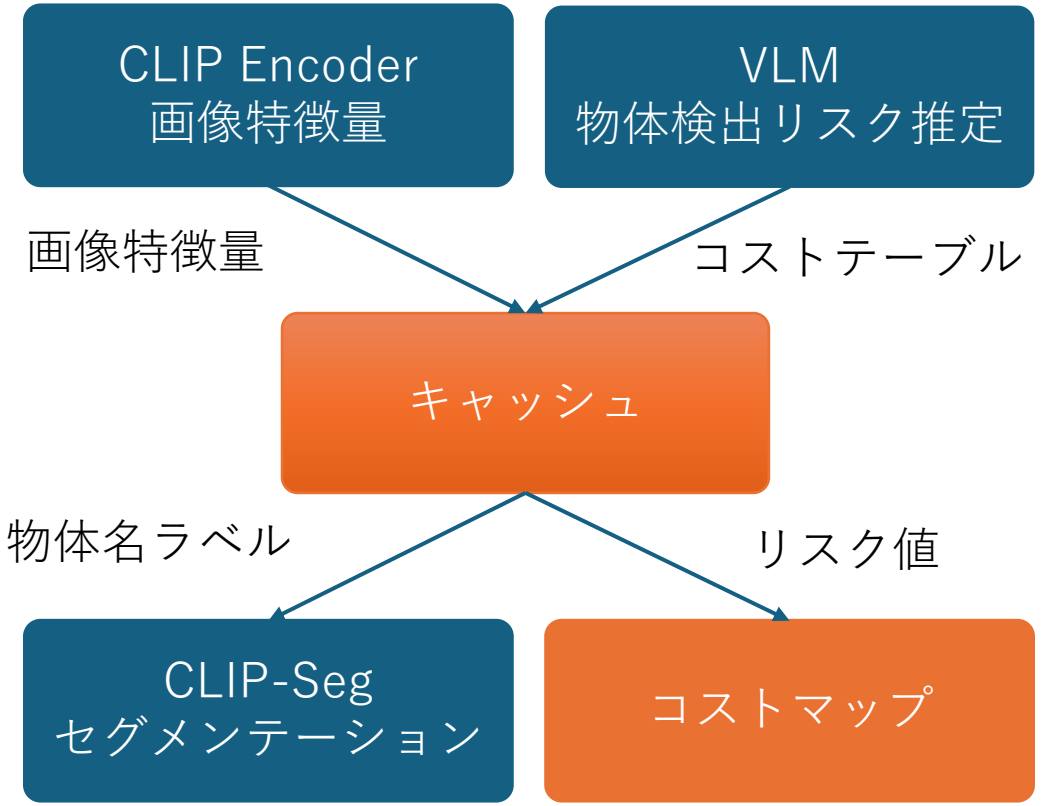



物体名とのアテンションの最大値をとることで、ゼロショットでセグメンテーション

# CLIP-Seg：セグメンテーション

各ピクセルのクラスに対するリスク値で
コストマップを作製

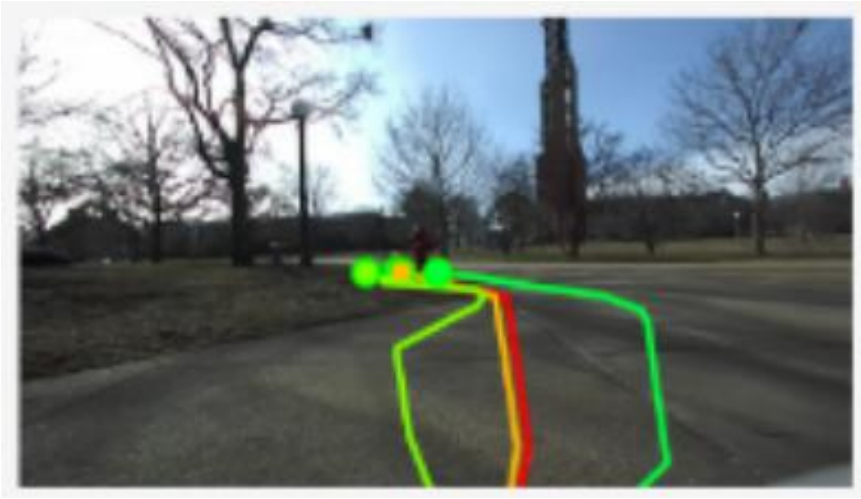
$$M(u,v) = \begin{cases} r_{k_c} & \text{if } p_{k_c}(u,v) > \delta, \\ 0 & \text{otherwise,} \end{cases},$$




セグメントされた領域にコストを乗せ、3Dから2Dに変換して2Dマップとして使う

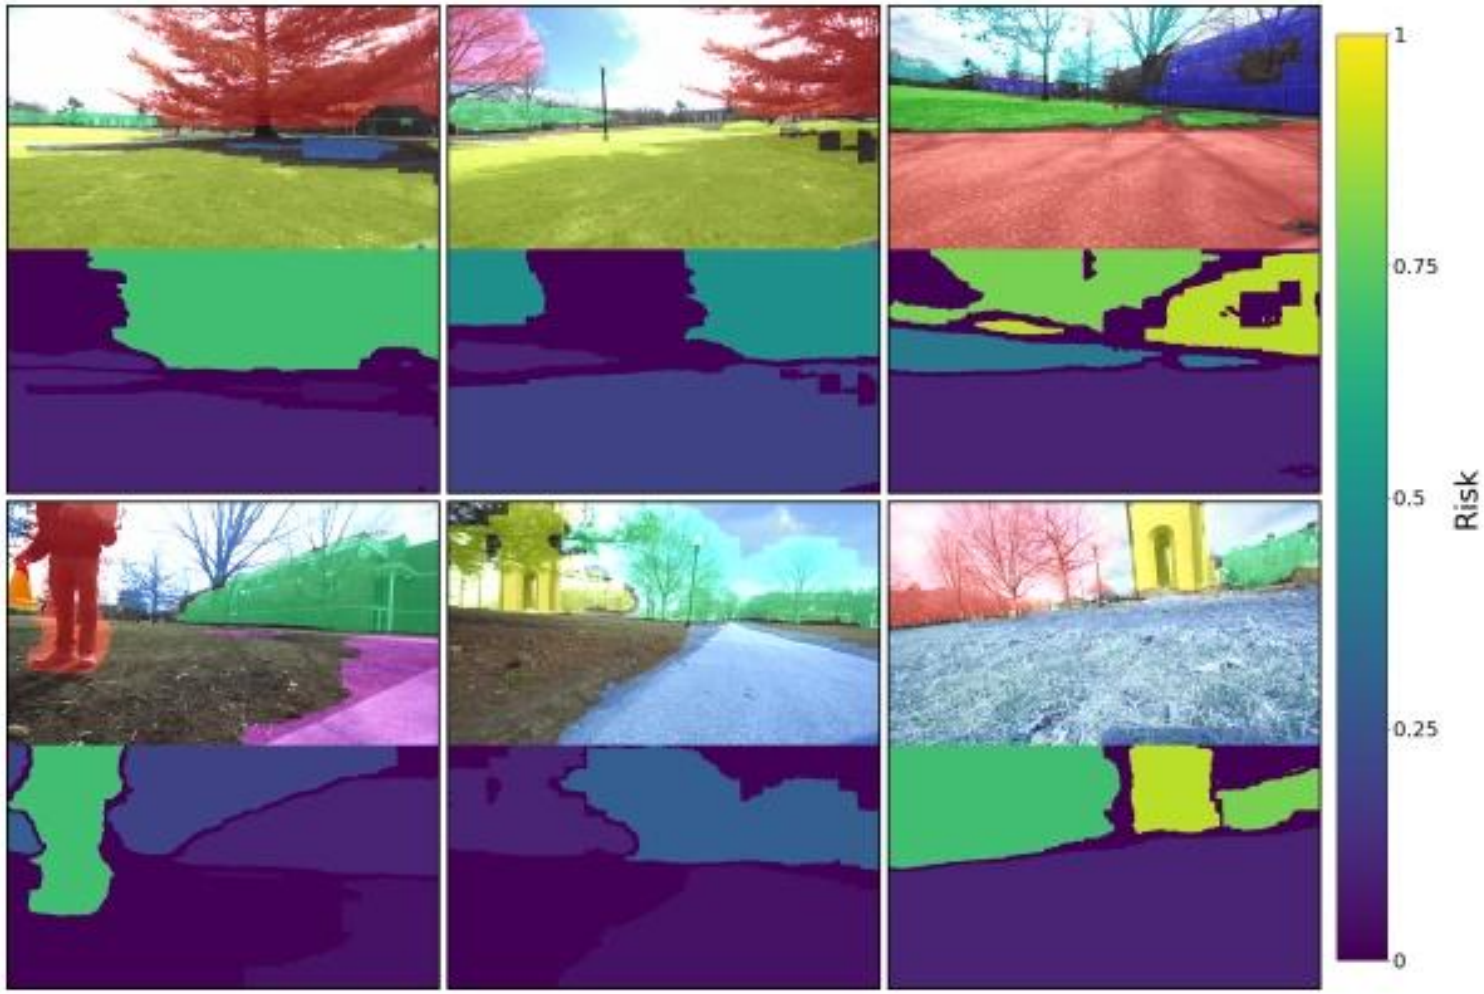
# 軌道生成と軌道選択

1. 中央軌道　：　TRRT(遷移ベースRRT)で経路を作成
2. 左軌道　　：　中央軌道を安全条件の範囲内で最大固定値d分左にずらす
3. 右軌道　　：　中央軌道を安全条件の範囲内で最大固定値d分右にずらす
4. リスク軌道：　安全閾値を緩めた条件でTRRTで軌道を再生成



複数の軌道を生成して、VLMに[道の種類]と[安全な理由]を考えて選ばせる

# 貢献1の結果：VLMによるコスト評価




セグメントされた領域ごとに、コストが判断されている。人や構造物はある程度高いリスクになっている

# 貢献2の結果：VLMのクエリの減少

TABLE II

VLM QUERY RATE COMPARISON ACROSS CONFIGURATIONS.

| | **Test 1** | **Test 2** | **Test 3** |
|---|---|---|---|
| Neighbors ($k$) | 1 | 5 | 5 |
| Novelty Threshold ($\gamma$) | 0.55 | 0.1 | 0.55 |
| ↓ Scene Queries | 16 | 125 | 9 |
| ↓ Path Selector Calls | 156 | 295 | 157 |
| ↓ Total VLM Queries | 172 | 420 | 166 |
| ↑ Cache Rate (C/s) | 0.044 | 0.104 | 0.194 |
| ↓ Query Rate (Q/s) | 0.004 | 0.042 | 0.006 |
| ↓ Avg Latency (s) | 3.937 | 17.35 | 3.717 |

Test2は多くの画像を新規性と判断する

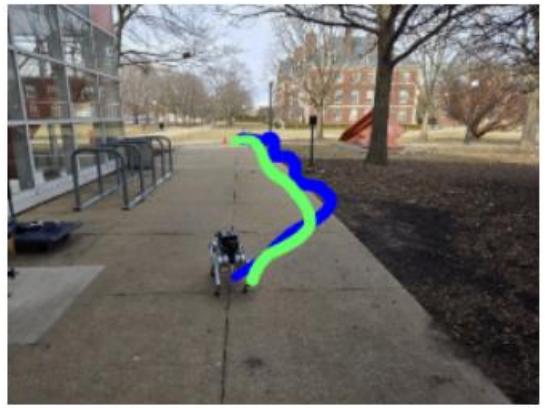
Test3はTest2に比べ、VLMに対するクエリを85.7%減らした

新規性の閾値を調整することで、画像の問い合わせ回数を減らすことができた

# 貢献3の結果：柔軟な経路選択

青：ベースライン、緑：CATNAV

| Method | Goal Reaching(%) ↑ | Dist. to Goal (m) ↓ | Collisions (%) ↓ | Behavior Breaks(%) ↓ |
|---|---|---|---|---|
| **Task 1: Navigate to cone, stay on right side of path (Static)** | | | | |
| OmniVLA | 60 | 2.7 | 20 | 40 |
| CATNAV (Ours) | 70 | 2.8 | 10 | 30 |
| **Task 2: Navigate to cone, stay in center of path (Static)** | | | | |
| OmniVLA | 50 | 2.3 | – | 20 |
| CATNAV (Ours) | 70 | 2.25 | – | 20 |
| **Task 3: Navigate to cone, (Human crosses path, Dynamic)** | | | | |
| OmniVLA | 60 | 0.4 | 20 | – |
| CATNAV (Ours) | 70 | 0.3 | 20 | – |
| **Task 4: Navigate to house (Avoid Collisions with Benches, Static)** | | | | |
| OmniVLA | 30 | 0.8 | 20 | – |
| CATNAV (Ours) | 40 | 0.7 | 30 | – |
| **Task 5: Go to door, avoid walking over the paper on the floor (Static)** | | | | |
| OmniVLA | 90 | 0.1 | 0 | 70 |
| CATNAV (Ours) | 90 | 0.1 | 0 | 30 |



a) Tasks 1–2: Footpath navigation



(b) Task 4: Bench avoidance



(c) Task 3: Dynamic obstacle



(d) Task 5: Paper avoidance

CATNAVは行動違反が少ない。また、紙をよけるという人間らしい柔軟な動きができている

# まとめ

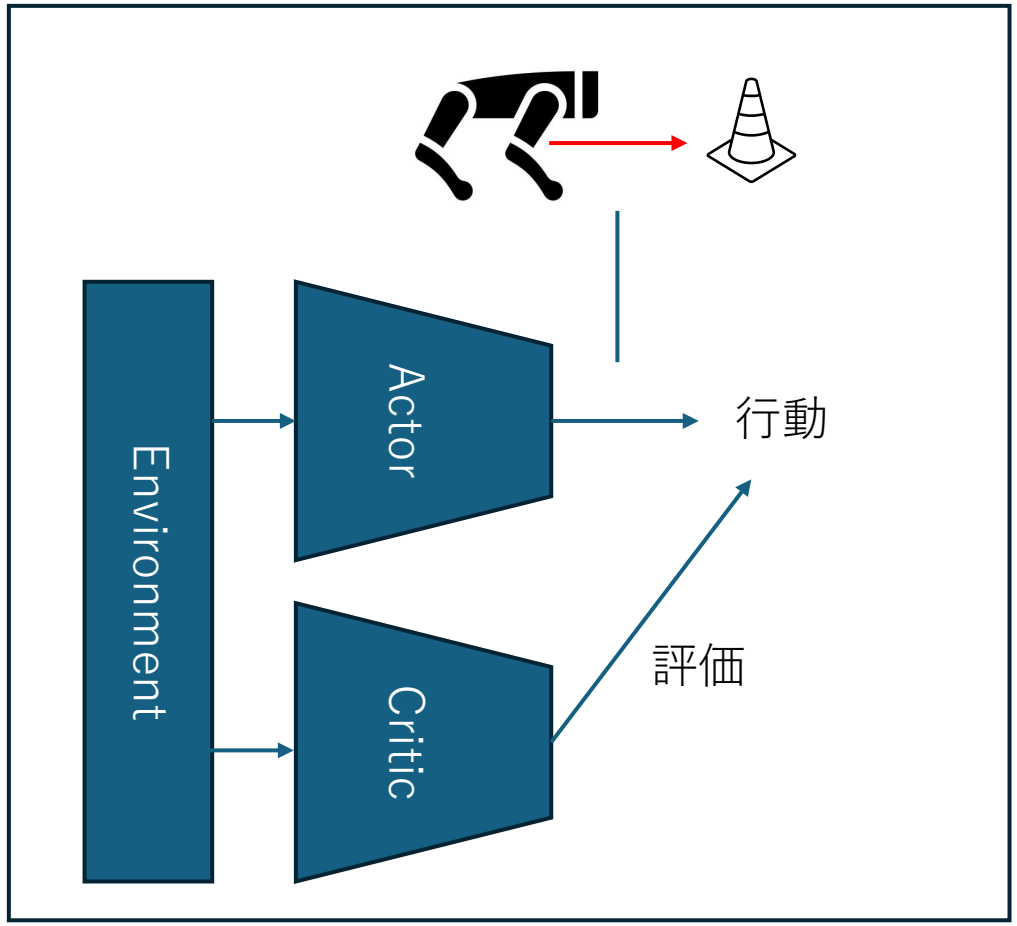
3つの貢献

1. タスク固有の学習は必要とせず、VLMの推論能力で意味的リスク値をゼロショットで推定
2. 画像の特徴量から類似シーンを検出し、リスク評価を再利用することでリソースの削減
3. RGB画像に乗せた複数経路から、視覚的に安全な経路を柔軟にVLMに選ばせる

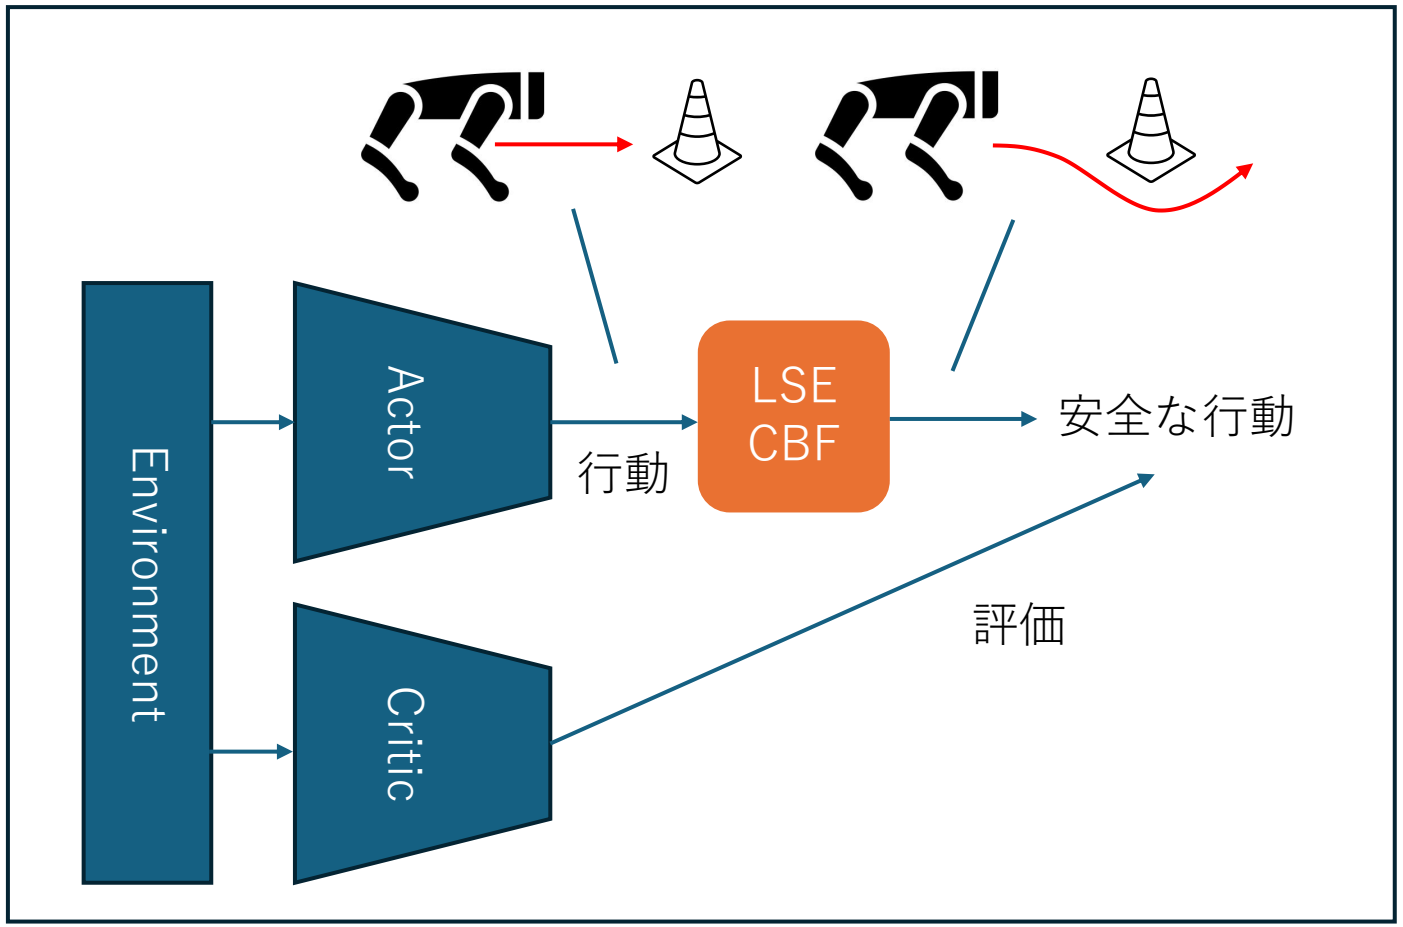
リミテーション

2D－3D変換でのノイズの発生
軌道にかかわる固定パラメータによる設定が数か所ある
CLIPSegなど、ある程度のシステム能力は求められる

# SEA-Nav: Efficient Policy Learning for Safe and Agile Quadruped Navigation in Cluttered Environments




通常のActor-Critic




SEA-Nav

# 背景

自立ナビゲーション
・密な障害物がある環境での自立移動は難しい → 安全性の向上が必要
・大規模な事前学習で、局所的な環境において高い性能が得られてきた

安全ナビCBF：Actor-Critic＋CBF
・CBFがどう干渉したかわからない問題
・失敗したらEP終了：その失敗データで学習したいのにとれる母数が少ない

# 従来手法

・模倣学習
　　行動をまねる
　　未知のデータで失敗しやすい

・深層強化学習
　　高い機動性が得られる
　　障害物が密集していると失敗が多い→サンプル効率が悪い
　　物理的な安全制限がかけずらい

・後処理安全フィルタ
　　Actor-Criticの外にCBFなどの安全フィルタがある
　　モデルが補正されていることを知らず、Actorの方策としての介入が不可能

問題点
・サンプル効率よく学習したい
・フィルタの介入も含めた学習で安全制御をしたい

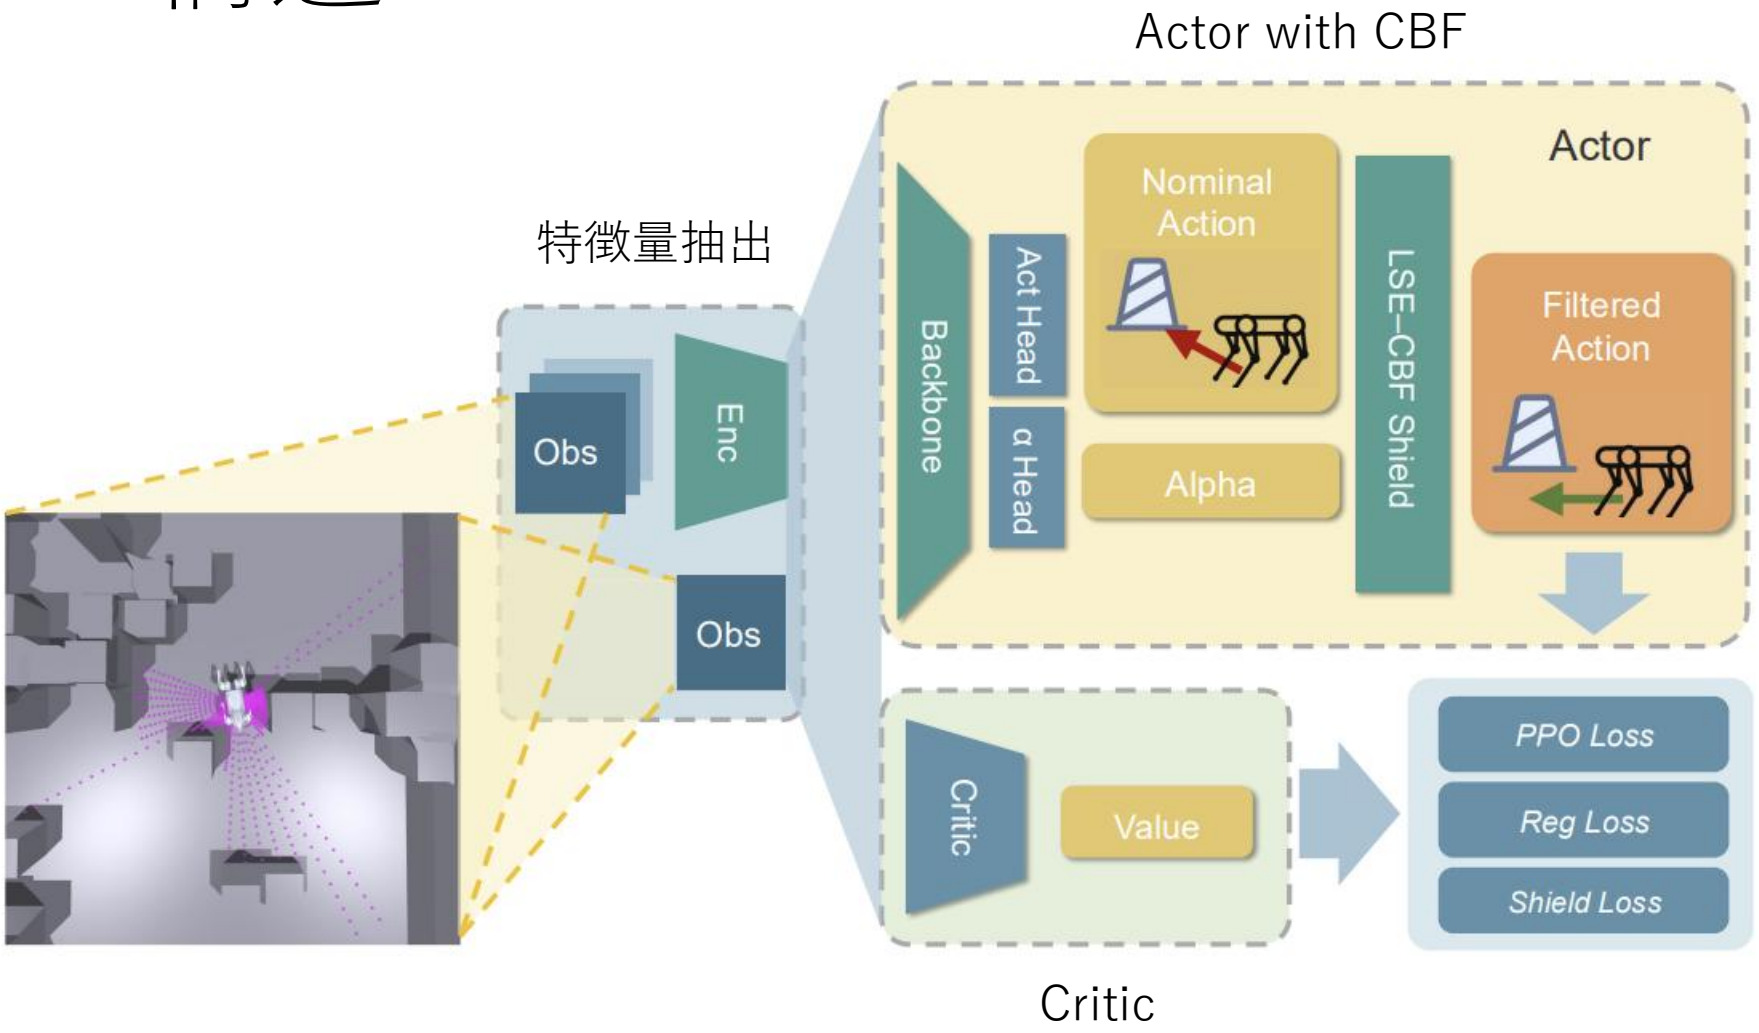
# 貢献

1. End2End LSE-CBF
   滑らかな学習予測と抑制で学習時とテスト時の不一致を解消

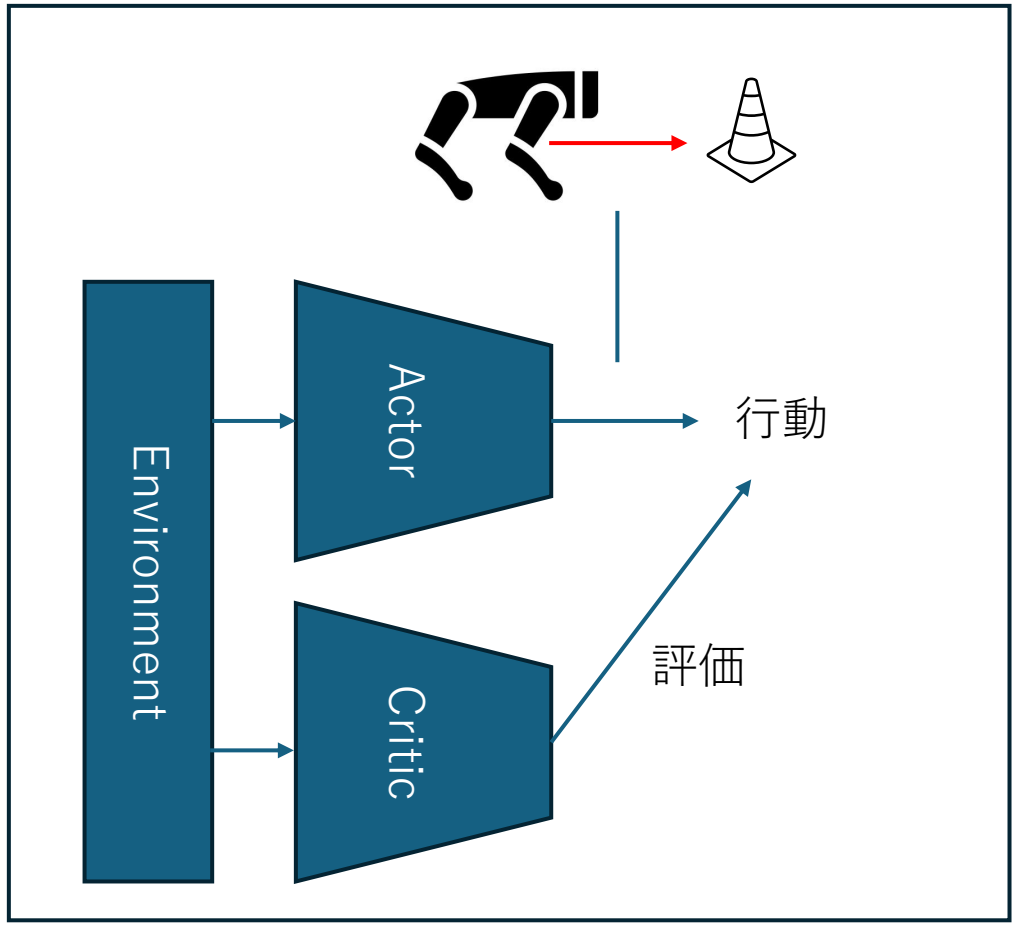
2. 運動学的行動正則化損失
   実環境への安全な適用

3. ACSI
   サンプリング効率よく、衝突前後にあるボトルネックの解消ができた

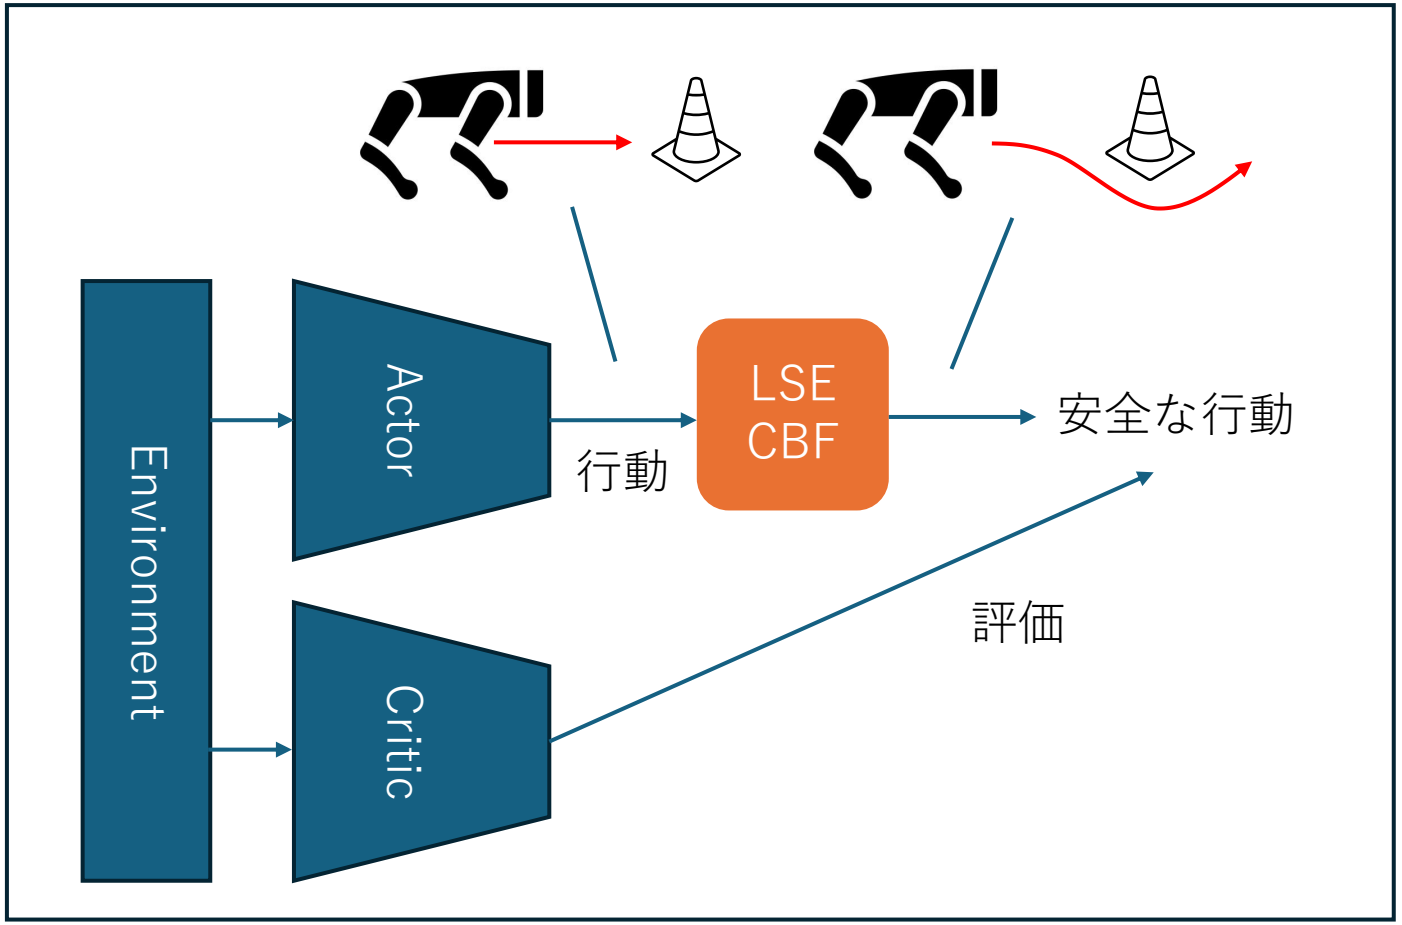
# モデル構造


Actor with CBF
特徴量抽出
Obs
Enc
Obs
Backbone
Act Head
α Head
Nominal Action
Alpha
LSE-CBF Shield
Actor
Filtered Action
Critic
Value
PPO Loss
Reg Loss
Shield Loss
Critic

# 貢献1：通常のActor-Criticとの大きな違い




通常のActor-Critic



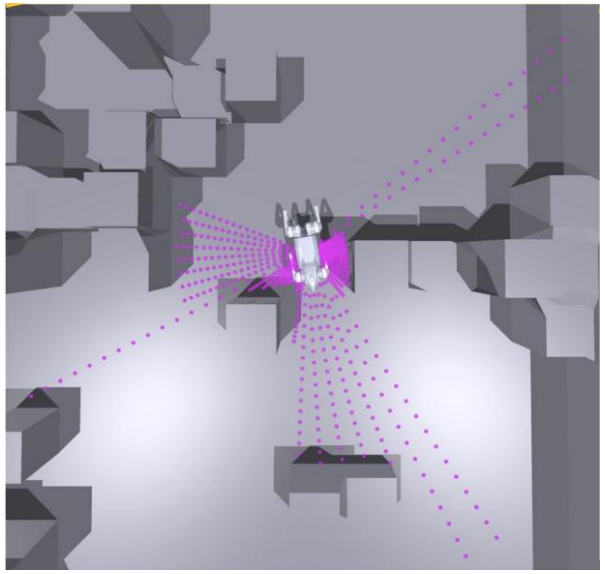

SEA-Nav

SEA-NavはCBFで安全範囲の行動を評価する

# Actorが決める行動

入力
・行動履歴10フレームの特徴量
・現在の観測
　　→41本のレイで、障害物までの距離を入力

出力
・希望速度指令
・CBFの安全制約に関するパラメータ$\alpha$



# LSE-CBF

各Rayに対する安全条件

$$h_i(x) = \rho_i - d_{safe}$$

通常のCBFの安全条件

$$h(x) = \min_{i \in \{1,\ldots,N\}} h_i(x)$$

安全条件にかかわる要素が変わると、
不連続になる

LSE-CBFの安全条件

$$h(x) = -\frac{1}{k} \ln \left( \sum_{i=1}^{N} \exp(-k \cdot h_i(x)) \right)$$

LSEの場合、連続であるため、
どの指令が悪いか、誤差伝播できる

CBFの安全制約

$$\dot{h}(x,u) \geq -\alpha h(x)$$

入力を安全な範囲に最小限動かす

$$\min_{u_s} \frac{1}{2} \|u_s - \bar{u}(x)\|^2 \quad \text{s.t.} \quad \langle L_g h(x), u_s \rangle + \alpha h(x) \geq 0$$

安全条件式を満たす範囲内で、安全な速度を出力し、Criticは安全な速度を評価する

# 貢献2：損失関数

$$L_{\text{total}} = L_{\text{PPO}} + \lambda_{\text{shield}} L_{\text{shield}} + \lambda_{\text{reg}} L_{\text{reg}}$$

$L_{ppo}$：PPO報酬
　ゴールへの達成報酬など
$L_{shild}$：CBFのパラメータの損失
　安全層が過剰介入したり、過剰抑制して元の入力が大きく変更されないようにする

$$L_{\text{shield}} = \|u_{s,t} - \bar{u}_t\|^2 + [\alpha_{\min} - \alpha_t]_+^2$$

$L_{reg}$：運動学的正則化損失、安全に滑らかに動くようにするための損失

安全：最大速度以上で動かないようにする　$L_{range} = \sum_{j \in \{x,y,\omega\}} \left( u_{s,t}^j - \text{clip}(u_{s,t}^j, u_j^{\min}, u_j^{\max}) \right)^2$

なめらか：急に方針を変えないようにする　$L_{smooth} = \lambda_\pi D\left(\pi_\theta(x_t), \pi_\theta(\bar{x}_t)\right) + \lambda_V D\left(V_\phi(x_t), V_\phi(\bar{x}_t)\right)$

運動家正則化報酬を入れることで、実機での適用における安全な出力を可能にする

# 貢献3：ACSIによるサンプリングの効率化

・直近2秒、100ステップ分のバッファを保持
・衝突後に大きなペナルティを与える
・確率的に巻き戻って学習
　　$P_{reset}$ の確率で早期終了し、次のエピソード開始
　　$P_{replay}$の確率で2秒巻き戻り、回避行動を再試行

・リセット率はゴール率に合わせて動的に変更

$$P_{reset} = P_{min} + (P_{max} - P_{min}) \cdot \mathrm{clip}\left(L_{goal}/1.5,\ 0,\ 1\right) \quad (1)$$

衝突した履歴を効率よくサンプリングできるため、局所的な学習が可能

# 結果

設定
- RTX 4090で2000iter学習(1時間)
- 10m四方にランダムに障害物を配置、密度はEasy Medium, Hardの3段階
- SR(成功率)、CR(衝突率)、TR(タイムアウト率)で評価

TABLE I

DIFFERENT DIFFICULTY LEVELS ARE EVALUATED; MEAN AND STANDARD DEVIATION ARE REPORTED OVER 3 EVALUATION RUNS OF 100 RANDOMIZED TRIALS EACH.

| Method | Easy | | | Medium | | | Hard | | |
|---|---|---|---|---|---|---|---|---|---|
| | SR (%) ↑ | CR (%) ↓ | TR (%) ↓ | SR (%) ↑ | CR (%) ↓ | TR (%) ↓ | SR (%) ↑ | CR (%) ↓ | TR (%) ↓ |
| **SEA-Nav (Ours)** | **100.00** (±0.00) | **0.00** (±0.00) | **0.00** (±0.00) | **97.00** (±0.82) | **1.00** (±0.82) | **2.00** (±0.00) | **90.00** (±1.63) | **5.00** (±0.82) | **5.00** (±0.82) |
| **SEA-Nav w/o ACSI** | **100.00** (±0.00) | **0.00** (±0.00) | **0.00** (±0.00) | 93.00 (±0.82) | 2.33 (±0.47) | 4.67 (±0.47) | 83.00 (±2.45) | 8.00 (±2.16) | 9.00 (±1.63) |
| **SEA-Nav w/o Shield** | 97.67 (±0.47) | 1.33 (±0.47) | 1.00 (±0.00) | 90.00 (±0.82) | 2.67 (±0.94) | 7.33 (±1.70) | 74.33 (±3.30) | 11.67 (±1.70) | 14.00 (±2.16) |
| **SEA-Nav w/o $L_{reg}$** | 96.33 (±0.47) | 2.67 (±0.47) | 1.00 (±0.00) | 82.33 (±2.05) | 6.00 (±0.82) | 11.67 (±1.25) | 57.00 (±4.08) | 18.00 (±2.16) | 25.00 (±2.16) |
| **ABS [7]** | 95.00 (±0.00) | 4.67 (±0.47) | 0.33 (±0.47) | 75.33 (±1.25) | 9.33 (±0.47) | 15.33 (±1.70) | 45.33 (±3.40) | 22.00 (±1.41) | 32.67 (±2.05) |
| **OCR [23]** | 95.33 (±0.47) | 3.33 (±0.47) | 1.33 (±0.47) | 67.33 (±2.49) | 31.33 (±2.87) | 32.67 (±2.49) | 56.00 (±3.27) | 18.33 (±2.49) | 25.67 (±2.49) |
| **REASAN [14]** | 95.67 (±0.47) | 2.67 (±0.47) | 1.33 (±0.47) | 71.33 (±3.09) | 10.33 (±1.89) | 28.67 (±2.16) | 77.67 (±4.62) | 14.33 (±1.89) | 22.33 (±4.19) |

貢献に対する3つの方法を入れることで、3つの環境での走破性が向上している

# 実機適用









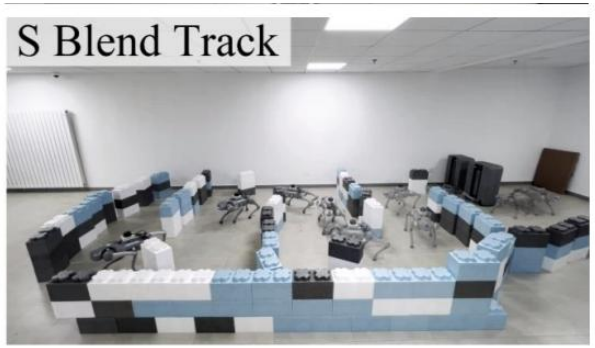




TABLE II

REAL-WORLD DEPLOYMENT RESULTS. AS: AVERAGE SPEED (M/S); SEA-NAV-B: BUILT-IN MPC CONTROLLER AND ONBOARD SPARSE LIDAR.

| Method | Cluttered Room | | | Dynamic Obstacle | | | Obstacle Course | | | S-Blend Track | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | SR (%) ↑ | CR (%) ↓ | AS (m/s) ↑ | SR (%) ↑ | CR (%) ↓ | AS (m/s) ↑ | SR (%) ↑ | CR (%) ↓ | AS (m/s) ↑ | SR (%) ↑ | CR (%) ↓ | AS (m/s) ↑ |
| SEA-Nav | **100** | 10 | 1.6 | 90 | 20 | 1.5 | **100** | 10 | **1.2** | **100** | 10 | **1.4** |
| SEA-Nav-b | **100** | 10 | 0.9 | **100** | 20 | 0.8 | 90 | 10 | 0.7 | **100** | 10 | 0.5 |
| ABS [7] | 70 | 50 | **2.1** | 60 | 10 | **1.7** | 0 | 100 | 0.6 | 80 | 20 | 0.8 |
| OCR [23] | 90 | 20 | 1.7 | 90 | 10 | 1.5 | 30 | 100 | 1.0 | 90 | 20 | 1.3 |
| REASAN [14] | 90 | 20 | 1.3 | 90 | 10 | 1.3 | 40 | 100 | 0.9 | 90 | 30 | 0.9 |
| SLAM | **100** | **0** | 0.5 | 80 | 40 | 0.4 | **100** | **0** | 0.4 | 80 | **0** | 0.3 |

SEA-Nav：オリジナル歩行モデル
SEA-Nav-b：Unitree公式歩行モデル

4つの環境の多くでSEA-Navが最も成功率が高い。

# Conclusion

貢献

1. End2End LSE-CBF
   滑らかな学習予測と抑制で学習時とテスト時の不一致を解消

2. 運動学的行動正則化損失
   実環境への安全な適用

3. ACSI
   サンプリング効率よく、衝突前後にあるボトルネックの解消ができた

リミテーション
・フラットな路面を想定していること
・複雑な行き止まりは未対応